

Abitudini alimentari e veganismo: un'analisi
multivariata e di sentiment sui dati statistici e
social media

Giulia Ciaralli, Gabriele Bagaglini

Indice

1	Introduzione	4
2	Contesto e rassegna della letteratura	5
2.1	Evoluzione storica della cultura alimentare italiana	5
2.2	La nascita della dieta mediterranea	6
2.3	La transizione contemporanea: dal <i>food</i> come bisogno al <i>food</i> come valore	7
2.4	Le diete <i>plant-based</i> : definizioni e modelli	7
2.4.1	Posizioni delle autorità scientifiche	8
2.5	Il mercato <i>plant-based</i> in Italia	9
3	Dati e metodi di analisi	10
3.1	Workflow di analisi	10
3.2	Metodologia e strumenti di analisi	11
4	Analisi del mercato	14
4.1	Statistiche descrittive e quadro di mercato attuale	14
4.1.1	Dati anagrafici	14
4.1.2	Abitudini di consumo alimentare	19
4.1.3	Chi sono i vegetariani?	21
5	Analisi delle associazioni tra variabili	25
5.1	Livello di istruzione e consumo di verdure	25
5.1.1	Regione di residenza e consumo di verdure	26
5.1.2	Sesso e consumo di verdure	27
6	Analisi delle serie temporali e pattern di crescita	29
6.1	BMI e analisi delle variazioni nella distribuzione dello stato pon- derale del campione	29
6.1.1	Analisi descrittiva della variabile BMI	30
6.1.2	Serie temporale del BMI	32
6.1.3	Associazione tra BMI e abitudini vegetariane	37
7	Metodi di riduzione della dimensionalità	39
7.1	Analisi delle componenti multiple (MCA)	39
7.1.1	Analisi delle corrispondenze multiple per gli individui tra i 18 e i 34 anni	39

7.1.2	Analisi delle corrispondenze multiple per gli individui tra i 45 e i 54 anni	45
8	Clustering gerarchico sulle componenti principali (HCPC)	48
9	Social media e Sentiment Analysis	50
9.1	Contesto della ricerca e obiettivi dell'analisi	50
9.2	Analisi dei commenti social italiani	50
9.2.1	Preprocessing e analisi lessicale del corpus	51
9.2.2	Analisi delle concordanze	53
9.2.3	Wordcloud	54
9.2.4	Analisi delle associazioni	56
9.2.5	Sentiment Analysis	58
9.2.6	Clustering tramite spherical k-means	59
9.3	Analisi testuale degli articoli sul tema veganismo	61
9.3.1	Studio e pulizia del dataset	61
9.3.2	Creazione del corpus e prime analisi	63
9.3.3	Algoritmo RAKE e Analisi delle Concordanze	66
9.3.4	Analisi comparativa secondo il periodo di pubblicazione	68
9.3.5	Analisi delle corrispondenze fattoriali e Clustering sul corpus	74
9.3.6	Latent Dirichlet Allocation per il topic modeling	77
9.3.7	Analisi del <i>sentiment</i>	84
9.4	Confronto tra analisi dei commenti italiani e degli articoli inter- nazionali	88
10	Conclusioni	90

1 Introduzione

Negli ultimi decenni, le abitudini alimentari sono diventate un tema centrale nel dibattito pubblico. Non riguardano solo la salute e la nutrizione, ma anche l'identità culturale, le scelte etiche e gli stili di vita. In questo contesto, fenomeni come il vegetarianismo e il veganismo non sono solo pratiche alimentari alternative, ma rappresentano anche oggetti di confronto sociale e simbolico, spesso caratterizzati da opinioni contrastanti e da un'abbondante produzione di contenuti, in particolare online.

Questo lavoro mira a esaminare questi fenomeni utilizzando un approccio integrato: combina l'analisi di dati statistici ufficiali sulle abitudini alimentari della popolazione con lo studio dei contenuti testuali sui social media e articoli giornalistici. L'obiettivo è comprendere sia le dimensioni strutturali del comportamento alimentare sia i modi in cui questo viene rappresentato, discusso e valutato online.

Una prima parte dell'analisi esplora i dati provenienti da fonti istituzionali utilizzando tecniche di analisi descrittiva, riduzione della dimensionalità e *clustering* per individuare profili, associazioni e schemi nei comportamenti alimentari.

La seconda parte del lavoro si concentra invece sull'analisi dei commenti sui social media e di articoli giornalistici. Qui si esamina il discorso pubblico relativo al veganismo e alle diete a base vegetale. Attraverso strumenti di *text mining*, *sentiment analysis* e analisi lessicometriche, si indaga la struttura semantica dei testi, le principali aree tematiche e il tono emotivo prevalente. Questo mette in luce le diverse dimensioni scientifiche, etiche e identitarie che caratterizzano il dibattito online. L'analisi si sviluppa anche in una prospettiva diacronica. Questo consente di osservare eventuali cambiamenti nel tempo nelle modalità espressive e nei contenuti del discorso.

In sintesi, l'obiettivo del lavoro è quello di offrire una lettura articolata del fenomeno alimentare contemporaneo, mostrando come i dati quantitativi e l'analisi dei testi possano integrarsi per fornire una comprensione più profonda delle pratiche sociali e delle rappresentazioni che le accompagnano.

2 Contesto e rassegna della letteratura

Il cibo rappresenta a pieno titolo un elemento culturale. Sebbene l'essere umano sia biologicamente onnivoro, le società non si nutrono degli stessi alimenti né li selezionano secondo criteri esclusivamente fisiologici: preferenze, avversioni e tabù alimentari derivano in larga misura da costruzioni culturali. Ogni comunità sviluppa infatti un proprio codice alimentare, che stabilisce quali cibi siano accettabili, desiderabili o, al contrario, da evitare. Tale codice nasce dall'intreccio di fattori geografici, ambientali, economici, storici e simbolici che caratterizzano una determinata cultura.

2.1 Evoluzione storica della cultura alimentare italiana

Per comprendere l'evoluzione della cultura alimentare italiana, è utile guardare alle sue radici storiche e ai modelli che l'hanno plasmata nel corso dei secoli. Verso la fine dell'alto Medioevo, intorno all'anno 1000, in Europa e nell'area mediterranea coesistevano due principali modelli alimentari, eredità di due civiltà contrapposte: quella classica greco-romana e quella barbarica. Il modello classico si fondava sulla triade pane-olio-vino, mentre quello barbarico privilegiava carne (soprattutto di maiale e selvaggina)-grassi animali-birra. Nel tempo, la tradizione barbarica si affermò soprattutto nel Nord Italia, in particolare nella Pianura Padana e in Emilia, dove si diffuse la cultura del maiale e dei salumi. Nel Mezzogiorno, invece, i contadini rimasero fedeli alla tradizione classica, continuando a coltivare grano, ulivo e vite. Fu proprio questa persistenza a permettere la conservazione dello stile alimentare mediterraneo, che sarebbe poi divenuto il nucleo della futura dieta mediterranea. Con il tempo, i due modelli — classico e barbarico — si fusero, influenzandosi reciprocamente: il pane, l'olio e il vino si diffusero anche nel Nord Europa, grazie anche al loro valore simbolico nella ritualità cristiana.

L'evoluzione dei consumi alimentari in Italia riflette in modo esemplare la trasformazione del Paese da società agricola povera a moderna economia avanzata. Per quasi un secolo dopo l'Unità, infatti, il regime alimentare degli italiani rimase sostanzialmente immutato: una dieta monotona, povera di proteine e grassi, basata su cereali, legumi e prodotti dell'autoconsumo, specchio di un Paese arretrato, segnato da malnutrizione diffusa e profonde disparità territoriali. Le lievi aperture della fine dell'Ottocento e gli effetti migliorativi della Prima guerra mondiale non alterarono la struttura di fondo, che anzi regredì durante il ven-

tennio fascista, quando le politiche autarchiche e le crisi produttive riportarono la popolazione, soprattutto urbana, a livelli alimentari estremamente precari. Il collasso definitivo si ebbe con la Seconda guerra mondiale, quando il cibo divenne un bene scarsissimo, distribuito in modo iniquo e insufficiente a garantire il minimo fabbisogno fisiologico: la fame e il mercato nero segnarono drammaticamente la vita quotidiana delle famiglie italiane. Solo con la Liberazione e grazie all'intervento massiccio degli aiuti americani si riuscì a interrompere la spirale della denutrizione, ripristinando gradualmente un livello calorico adeguato.

A partire dagli anni Cinquanta, però, si aprì una fase completamente nuova: la crescita del reddito, la modernizzazione industriale e l'ingresso nei mercati internazionali innescarono un rapido e inedito aumento dei consumi alimentari, sia in quantità sia in varietà. In questo contesto mutò radicalmente la dieta degli italiani, che vide crescere in modo esponenziale il consumo di carne, latte, ortaggi, frutta e oli, mentre si riduceva progressivamente il peso dei cibi poveri come granturco, strutto, legumi secchi e farine minori.

2.2 La nascita della dieta mediterranea

Fu proprio in quel periodo che il biologo americano Ancel Keys, impegnato in Italia per studi sull'alimentazione, rimase colpito dalla sorprendentemente bassa incidenza di malattie cardiovascolari in alcune aree del Mediterraneo, in particolare Campania, Calabria e Creta. Per indagarne le cause avviò ricerche sul campo, stabilendo il proprio centro di studio a Pioppi (Cilento) e analizzando le abitudini alimentari delle popolazioni locali.

Dai suoi studi emerse che un'alimentazione basata su pane, pasta, frutta, verdura, legumi, olio d'oliva, con un consumo moderato di carne e maggiore apporto di pesce, era legata a una migliore salute e maggiore longevità (Foto 1). Keys definì questo modello "Mediterranean Diet", diffondendolo negli Stati Uniti con il libro *Eat Well and Stay Well*.

La rilevanza culturale e sociale di questo stile alimentare ha portato, nel 2010, al suo riconoscimento come Patrimonio Culturale Immateriale dell'Umanità UNESCO, non solo per i benefici nutrizionali, ma perché rappresenta uno stile di vita completo, fatto di tradizioni agricole, tecniche culinarie, ritualità, convivialità, rispetto del territorio e trasmissione intergenerazionale di saperi. La dieta mediterranea non è dunque un semplice schema alimentare, ma un patrimonio identitario delle comunità del Mediterraneo.




Figura 1: La piramide alimentare

2.3 La transizione contemporanea: dal *food* come bisogno al *food* come valore

Ma negli ultimi cinquant'anni, come in molti paesi avanzati, c'è stata una vera e propria rivoluzione degli stili alimentari. L'aumento dell'istruzione, gli scandali alimentari del passato, la crescente urbanizzazione e industrializzazione e la maggiore consapevolezza ambientale hanno modificato il rapporto delle persone con il cibo. Mai come in questo momento c'è la percezione, da parte dei cittadini, dell'importanza dell'alimentazione, del territorio e dell'ambiente, in un mercato mondiale sempre più globalizzato. Da bisogno primario, il cibo è diventato un valore complesso legato ad aspetti psicologici e socioculturali, etici e ambientali. L'attenzione per il cibo, diffusasi a tutti i livelli, merita una seria puntualizzazione sul percorso di esperienze di informazione ed educazione alimentare di cui l'Italia è stata protagonista.

2.4 Le diete *plant-based*: definizioni e modelli

Si definisce vegetariano chi non assume carni di animali terrestri e marini. I modelli più diffusi e studiati in letteratura sono:

- **Latto-ovo-vegetariano (LOV)**: escludono tutti i tipi di carne ma includono latticini, uova, miele.

- **Vegani (VEG):** escludono tutti gli alimenti di origine animale e i loro derivati.

Nel più ampio panorama dell'alimentazione a base vegetale (*plant-based*) esistono anche altri regimi più restrittivi:

- **Crudismo**, basato esclusivamente su cibi non cotti;
- **Fruttarismo**, focalizzato su frutta fresca e secca, semi e alcuni ortaggi;
- **Dieta macrobiotica**, basata su cereali, legumi, verdura, alghe e prodotti a base di soia.



Figura 2: Un banchetto vegetariano

2.4.1 Posizioni delle autorità scientifiche

Secondo l'OMS, la carne rossa è classificata come “probabilmente cancerogena” (gruppo 2A), mentre la carne processata (affettati, salumi, wurstel, ecc..) rientra tra le sostanze “cancerogene per l'uomo” (gruppo 1), per cui esistono prove epidemiologiche solide del legame con patologie tumorali. La letteratura scientifica solitamente accorpa i dati che riguardano la dieta vegana e quella vegetariana, pertanto risulta difficile scindere gli effetti che questi due regimi alimentari determinano. Ad ogni modo, è stato dimostrato che la dieta vegana e quella vegetariana, se ben bilanciate, hanno diversi benefici per la salute e per l'ambiente; infatti, sono associate a una riduzione del rischio di eventi cardiovascolari, diabete, ipertensione, demenza e cancro, oltre ad avere un minore

impatto ambientale. Allo stesso tempo, tali diete richiedono particolare attenzione all'apporto di alcuni micronutrienti, tra cui la vitamina B12, presente quasi esclusivamente in alimenti di origine animale e quindi da integrare.

2.5 Il mercato *plant-based* in Italia

Parallelamente alla diffusione delle diete vegetariane e vegane, diversi studi hanno indagato caratteristiche e motivazioni dei consumatori. Secondo Eurispes (2021), le ragioni alla base del cambiamento delle proprie abitudini alimentari sono molteplici: motivazioni filosofiche (23,1%), salute personale (21,3%), etica animale (20,7%), impatto ambientale (11,2%), desiderio di cambiare stile alimentare (9,5%) e attenzione alla qualità del cibo (5,9%).

Dati più recenti di YouGov Shopper (2024) confermano la crescita della gastronomia vegetale e tracciano il profilo dell'acquirente tipo. Analizzando i dati relativi alla gastronomia vegetale fresca o surgelata, emerge che gli acquirenti di prodotti plant-based vivono prevalentemente nel Nord Italia, appartengono a classi socioeconomiche medio-alte, hanno più di 45 anni e non hanno figli. Oltre il 60% dei nuclei è composto da una sola persona o da coppie senza figli. In Italia quasi 3 milioni di persone dichiarano di seguire uno di questi regimi alimentari: 2,1 milioni di vegetariani (3,7% della popolazione) e 855.000 vegani (1,5%). Secondo l'indagine, le motivazioni principali che portano a queste scelte sono lo stile di vita sostenibile (32%) e la salute personale (31%). I consumatori vegetariani e vegani sono soprattutto donne (55%) e residenti al Nord (52%). Rispetto alla media nazionale, sono più ambientalisti (34% contro il 12%) e prediligono marchi e aziende che dimostrano un impegno concreto per cause sociali e ambientali. Prestano maggiore attenzione alle etichette e agli ingredienti (31% contro il 20% della media) e risultano più pet-friendly, con il 47% che possiede due o più animali domestici rispetto al 30% nazionale.

3 Dati e metodi di analisi

3.1 Workflow di analisi

L'analisi è stata condotta sulla base dell'indagine, a cadenza annuale, effettuata da Istat denominata "Aspetti della vita quotidiana", durante la quale è stato intervistato un campione di circa 20000 famiglie e 50000 individui. L'obiettivo è quello di rilevare le informazioni fondamentali relative alla vita quotidiana degli individui e delle famiglie italiane. Le informazioni raccolte consentono di conoscere le abitudini dei cittadini e i problemi che essi affrontano ogni giorno. All'interno dei questionari si susseguono aree tematiche su aspetti sociali diversi, permettendo di capire come vivono gli individui e quanto sono soddisfatti delle loro condizioni, della situazione economica, della zona in cui vivono, del funzionamento dei servizi di pubblica utilità che dovrebbero contribuire al miglioramento della qualità della vita. Dalla nota metodologica compresa nelle pubblicazioni di Istat si legge che il campione dell'indagine è stato selezionato seguendo un disegno probabilistico stratificato, al fine di garantire la rappresentatività della popolazione di riferimento. In particolare, la popolazione è stata suddivisa in strati definiti sulla base delle regioni geografiche e della dimensione demografica dei comuni, e da ciascuno di questi strati sono stati estratti i diversi elementi campionari mediante campionamento casuale semplice. Inoltre, i dati raccolti sono stati "pesati" per correggere eventuali differenze dovute a persone che non hanno risposto o a gruppi meno rappresentati, così che il campione rispecchi il più possibile la popolazione reale per età, sesso e area di residenza. Il risultato dell'indagine è stato riassunto in una tabella di dati caricata sul sito di Istat, che conta 708 colonne per il 2023, una per ogni domanda rivolta all'intervistato (Il numero di domande totali è variato durante gli anni). Tenuto conto delle dimensioni del dataset e degli scopi del progetto, si è considerato unicamente il dataset relativo all'anno 2023 (il più recente). In seguito, sono state estratte le variabili di interesse, in particolare quelle riguardanti le abitudini alimentari del campione oltre ad alcuni dati anagrafici come sesso, età, titolo di studio e condizione professionale. Da queste, sono state escluse quelle con un'occorrenza di "NA" superiore al 3 - 4 per cento, per conservare l'integrità delle valutazioni fatte sul campione. Il questionario somministrato al campione è formato da domande a risposta multipla, con ciascuna opzione numerata; la risposta scelta dall'intervistato viene riportata in tabella secondo il numero associato. Il risultato è un dataset a prevalenza di dati qualitativi, che deriva dalla

struttura tipica dei questionari, organizzati per fasce di risposte. Di conseguenza, si è proceduto a trasformare le variabili interessate in fattori, provvedendo anche a rinominare i valori secondo le diciture presenti nel tracciato. Di seguito si mostra un esempio di domanda posta al campione intervistato.

3.5 Con che frequenza consuma i seguenti gruppi di alimenti?
(una risposta per ogni riga)

		Più di una volta al giorno	Una volta al giorno	Qualche volta a setti- mana	Meno di una volta a setti- mana	Mai
Pane, pasta, riso	1	☐	2 ☐	3 ☐	4 ☐	5 ☐
Salumi	1	☐	2 ☐	3 ☐	4 ☐	5 ☐
Carne di pollo, tacchi- no, coniglio, vitello.....	1	☐	2 ☐	3 ☐	4 ☐	5 ☐
Carni ovine (agnello, pecora, capra)	1	☐	2 ☐	3 ☐	4 ☐	5 ☐
Carni bovine (manzo, vitellone, ecc.)	1	☐	2 ☐	3 ☐	4 ☐	5 ☐
Carni di maiale (escluso salumi)	1	☐	2 ☐	3 ☐	4 ☐	5 ☐
Latte	1	☐	2 ☐	3 ☐	4 ☐	5 ☐
Formaggi, latticini	1	☐	2 ☐	3 ☐	4 ☐	5 ☐
Uova	1	☐	2 ☐	3 ☐	4 ☐	5 ☐
Pesce	1	☐	2 ☐	3 ☐	4 ☐	5 ☐

Figura 3: domanda estratta dal questionario

Il dataset finale utilizzato per l'analisi è costituito da 41750 osservazioni (per il 2023) e da 21 variabili. Queste riguardano due aree principali:

1. **Variabili socio-demografiche**, che descrivono le caratteristiche individuali fondamentali dell'intervistato.
2. **Variabili alimentari**, ciascuna relativa alla frequenza di consumo di un particolare alimento.

3.2 Metodologia e strumenti di analisi

L'intera analisi è stata condotta utilizzando il linguaggio di programmazione R, che ha permesso di gestire in maniera integrata tutte le fasi del lavoro, dalla preparazione e pulizia dei dati all'analisi statistica multivariata. Per quanto riguarda l'analisi testuale e del sentiment, è stato inoltre utilizzato IRaMuTeQ,

Tabella 1: Variabili socio-demografiche

Variabile	Significato
NCOMP	Numero di componenti del nucleo familiare
ANNO	Anno di rilevazione
ETAMi	Classe d'età
SESSO	Sesso
STCIVMi	Condizione professionale
ISTRMi	Titolo di studio
REGMf	Regione di residenza
BMI	Classe di indice di massa corporea

Tabella 2: Variabili alimentari

Variabile	Significato
VERD	Verdura
FRUTTA	Frutta
SALUMI	Salumi
CBOV	Carne bovina
PESCE	Pesce
POLLO	Pollo
CMAIAL	Carne di maiale
LATTE	Latte
FORM	Formaggi
UOVA	Uova
POMOD	Pomodori
LEGUMI	Legumi
PATATE	Patate

software open-source che integra R e Python e che consente l'applicazione di metodologie statistiche e lessicometriche per l'analisi automatica dei testi, come l'analisi delle specificità, l'analisi fattoriale delle corrispondenze e la classificazione automatica dei testi secondo il metodo di Reinert.

4 Analisi del mercato

4.1 Statistiche descrittive e quadro di mercato attuale

Come anticipato in precedenza, i dati che sono derivati dal questionario sono per lo più qualitativi, ad eccezione del numero di componenti del nucleo familiare dell'intervistato. Pertanto, l'analisi descrittiva ha riguardato il calcolo delle frequenze per ciascuna variabile, e il corrispondente grafico a barre che rappresenta la distribuzione delle suddette frequenze all'interno del dataset. Si è proceduto inizialmente con una valutazione di natura prevalentemente anagrafica, su variabili come l'età, il sesso, la condizione professionale e l'istruzione. Successivamente, è stato disegnato il quadro generale delle variabili relative alle abitudini alimentari, a partire dalle quali è stato possibile individuare i soggetti praticanti una dieta vegetariana o vegana.

4.1.1 Dati anagrafici

In questa sezione vengono discusse le caratteristiche personali dei soggetti, commentando il comportamento del campione rispetto a ciascuna variabile. L'obiettivo è quello di disegnare un quadro generale del campione intervistato, e in seguito associare le informazioni raccolte con le sue abitudini di consumo alimentare.

La colonna relativa alla variabile **numero di componenti** è la sola di natura quantitativa presente nel dataset; pertanto, è stata trattata diversamente rispetto alle altre in questa fase dell'analisi.




Figura 4: Distribuzione del numero di componenti

Tabella 3: Statistiche descrittive del numero di componenti

Statistica	Valore
Media	2.89
Mediana	3
Moda	2
Valore minimo	1
Valore massimo	9
Range	1-9
Varianza	1.68
Deviazione standard	1.29

La distribuzione riportata nel grafico e le statistiche descrittive in tabella permettono di delineare in modo chiaro la struttura dei nuclei presenti nel campione. La distribuzione delle frequenze risulta concentrata principalmente sui valori compresi tra 1 e 4 componenti, con una netta prevalenza dei nuclei composti da 2 persone, che rappresentano la modalità più frequente. Anche i nuclei da 3 e 4 componenti mostrano una presenza significativa, mentre le frequenze diminuiscono rapidamente oltre tali valori. Le statistiche descrittive confermano quanto osservato visivamente: la media si attesta a circa 2.89 componenti, mentre la mediana è pari a 3, indicando che metà della popolazione vive in nuclei di tre o meno persone. La moda, pari a 2 componenti, rappresenta la configurazione più tipica all'interno del campione. Il range varia da 1 a 9 componenti, ma le occorrenze relative ai nuclei più numerosi risultano molto contenute e non influenzano in modo sostanziale l'andamento complessivo della distribuzione.




Figura 5: *Boxplot* del numero di componenti

Infine, il boxplot del numero di componenti conferma visivamente quanto emerso dalla distribuzione delle frequenze. La parte centrale del grafico mostra una concentrazione delle osservazioni tra 2 e 4 componenti, con una mediana pari a 3. L'estensione limitata dell'intervallo interquartile indica una variabilità contenuta all'interno della maggior parte dei nuclei familiari. Si osservano inoltre alcuni valori più elevati, segnalati come outlier, che rappresentano famiglie di dimensioni maggiori ma che risultano poco frequenti nel campione.

Nel complesso, la variabile riflette la tendenza demografica verso nuclei familiari di dimensioni ridotte, con una forte concentrazione su valori medio-bassi e una

presenza limitata di famiglie numerose. La combinazione di grafico e statistiche sintetiche descrive dunque una popolazione prevalentemente composta da piccoli nuclei, caratteristica coerente con il quadro socio-demografico italiano contemporaneo.

Il resto delle colonne è di natura qualitativa, e per tale motivo è necessario adattarne l'analisi di conseguenza. La variabile **età** è codificata in 15 classi ordinali, che corrispondono a fasce d'età (0–2 anni, 3–5 anni, 6–10 anni, ..., 75+ anni). Il grafico a barre seguente mostra la distribuzione delle frequenze nelle diverse categorie.




Figura 6: Distribuzione delle frequenze per la variabile "età"

Il grafico mostra una marcata asimmetria verso destra (*right-skewed*). Le prime classi (bambini e adolescenti) hanno pochissime osservazioni. La numerosità cresce progressivamente verso le fasce adulte di mezza età. La moda è rappresentata dalla classe 11, che si riferisce alla fascia d'età 45-54. Si tratta quindi di un campione fortemente sbilanciato verso la popolazione adulta e anziana, e molto poco rappresentativo di bambini e giovani, con la maggior parte del campione che si concentra tra i 45 e i 74 anni.

Come prevedibile in indagini di questo tipo, il campione si è dimostrato equamente distribuito nel numero di uomini e donne (circa il 48% per gli uomini e il restante 52% per le donne)

Per quanto riguarda la variabile **istruzione**, il grafico sottostante mostra la distribuzione delle frequenze nelle diverse classi previste dalla codifica ISTAT,

opportunamente rinominate, che distingue i livelli di istruzione degli intervistati.




Figura 7: Distribuzione delle frequenze per la variabile "istruzione"

Le frequenze non risultano uniformi: si osserva una marcata prevalenza della categoria "diploma", che rappresenta la classe nettamente più numerosa nel campione. Anche la categoria immediatamente successiva, "licenza di scuola media", presenta una numerosità elevata, confermando una forte concentrazione nelle fasce di istruzione di medio livello tipiche della popolazione adulta italiana. Le categorie estreme risultano invece molto meno rappresentate: da un lato, la categoria "laurea o post-laurea" è sensibilmente meno frequente rispetto ai titoli intermedi; dall'altro, la categoria "licenza elementare o nessun titolo di studio" presenta proporzioni contenute, come prevedibile in un paese ad alta scolarizzazione come l'Italia. Inoltre, è presente una categoria residuale (circa l'1.8% del totale) etichettata "non disponibile" per gli intervistati che non hanno reso nota questa informazione.

Nel complesso, la distribuzione risulta quindi sbilanciata verso i livelli di istruzione intermedi, leggermente asimmetrica verso destra, con un picco nella popolazione diplomata e una graduale diminuzione al procedere verso titoli molto alti o molto bassi. Tale struttura riflette in modo plausibile la composizione della popolazione adulta italiana, caratterizzata da una forte prevalenza di diplomati, una quota significativa di individui con licenza media e una presenza più ridotta di soggetti con titoli universitari o bassi livelli di scolarità.

Per quanto riguarda la variabile **stato civile**, il grafico riportato di seguito mo-

stra la distribuzione delle frequenze nelle diverse modalità previste dalla codifica ISTAT, opportunamente rinominate per una maggiore leggibilità dei risultati.




Figura 8: Distribuzione delle frequenze per la variabile "stato civile"

Il grafico mostra un andamento non uniforme. La categoria più frequente è quella dei “coniugati/e”, che rappresenta una quota consistente del campione, riflettendo la composizione tipica della popolazione adulta italiana. Segue la categoria “celibe/nubile”, anch’essa numerosa ma leggermente meno rispetto ai coniugati. Le modalità “separato/a” e “vedovo/a” presentano invece frequenze più contenute, mentre la classe “non disponibile” è marginale e indica casi in cui l’informazione non è stata fornita.

L’insieme delle distribuzioni suggerisce una popolazione concentrata principalmente nelle fasi centrali del ciclo di vita, caratterizzate da una maggiore probabilità di essere coniugati o, in alternativa, non aver ancora contratto matrimonio. Un altro degli aspetti valutati riguarda la regione di residenza del campione, con lo scopo di determinare come il campione si distribuisce nelle diverse aree geografiche del paese.




Figura 9: Distribuzione delle frequenze per la variabile "regione di residenza"

Nel grafico a barre le singole regioni sono etichettate secondo la codifica ISTAT riportata nel dataset. La distribuzione non risulta uniforme e presenta variazioni considerevoli tra le regioni. Le categorie maggiormente rappresentate comprendono regioni ad alta densità demografica come Lombardia, Piemonte, Campania, che mostrano frequenze più elevate rispetto alle altre. In particolare, la Lombardia è la regione nettamente più rappresentata. Al contrario, regioni con popolazione più contenuta — come Valle d'Aosta, Molise o Basilicata — mostrano frequenze decisamente inferiori, come prevedibile. Nel complesso la distribuzione rispecchia in modo plausibile il quadro demografico nazionale, con una maggiore concentrazione degli intervistati nelle regioni più popolate del Centro-Nord e in alcune regioni del Sud ad alta densità. Tale configurazione suggerisce che il campione, pur non essendo perfettamente uniforme sul territorio, risulta proporzionale alla reale distribuzione della popolazione.

4.1.2 Abitudini di consumo alimentare

In questa sezione l'attenzione si sposta sull'analisi delle variabili relative alle abitudini di consumo alimentare degli intervistati. L'obiettivo è quello di individuare differenze nelle diete all'interno del campione, ponendo una particolare attenzione alla rapporto tra l'individuo e gli alimenti vegetali, o ,in generale, di provenienza non animale

Le variabili relative al consumo di salumi, carne bovina e pesce presentano distribuzioni molto simili, caratterizzate da una forte concentrazione nelle categorie centrali della scala di risposta.




Figura 10: Distribuzione delle frequenze per le variabili salumi, carne bovina e pesce

In tutti e tre i casi la maggior parte degli intervistati dichiara un consumo compreso tra “una volta al giorno” e “meno di una volta a settimana”, con una frequenza più elevata nella categoria “qualche volta a settimana”. Questa categoria è quella più comune in ciascuna delle tre variabili, suggerendo una tendenza generalizzata a un consumo moderato e non quotidiano di tali alimenti. Le modalità estreme, ovvero il consumo molto frequente (“più di una volta al giorno”) e il non consumo (“mai”), risultano poco rappresentate per tutte e tre le variabili. Tale pattern indica che sia i salumi, sia la carne bovina, sia il pesce sono consumati dalla maggior parte degli intervistati con una frequenza regolare ma non eccessiva, mentre il consumo quotidiano o l’astensione totale sono comportamenti minoritari. Nel complesso, le tre distribuzioni presentano una forma marcatamente simile, centrata sulle classi intermedie e caratterizzata da una moderata asimmetria verso destra. Questa omogeneità suggerisce che tali prodotti, pur appartenendo a categorie alimentari diverse, condividono un ruolo comparabile nelle abitudini alimentari della popolazione considerata.

Le distribuzioni relative al consumo di pollo e di carne maiale delineano due

alimenti opposti ed estremi nelle abitudini di consumo del campione.




Figura 11

La variabile **pollo** mostra una distribuzione nettamente più centrata e meno asimmetrica rispetto alle altre carni: la maggior parte degli intervistati dichiara un consumo collocato nella categoria centrale “qualche volta a settimana”, con una ridotta presenza sia dei consumi molto frequenti sia dell’astensione totale. In particolare, anche la categoria "meno di una volta a settimana" non è così frequente come per gli altri alimenti animali. Questo andamento suggerisce che il pollo rappresenti un alimento consumato con regolarità e in modo relativamente omogeneo all’interno del campione.

Di contro, la distribuzione della variabile **carne di maiale** risulta più sbilanciata verso le classi di consumo meno frequenti. Pur registrando anch’essa un picco nella categoria centrale, essa presenta proporzioni più elevate nelle fasce che indicano un consumo sporadico o raro, evidenziando quindi una maggiore variabilità nelle abitudini alimentari. L’asimmetria più marcata della distribuzione del maiale, combinata con la maggiore presenza nelle categorie basse, indica che questo alimento viene consumato meno regolarmente e con maggiore eterogeneità rispetto al pollo. Nel complesso, le due variabili delineano uno scenario in cui il pollo rappresenta un alimento più integrato nella dieta settimanale media degli intervistati, mentre la carne di maiale mostra pattern di consumo più irregolari e tendenzialmente meno frequenti.

4.1.3 Chi sono i vegetariani?

Il vegetarianismo o vegetarismo o vegetarianesimo designa, nell’ambito della nutrizione umana, un insieme di diverse pratiche alimentari che escludono dal-

l'alimentazione la carne di qualsiasi animale (in primo luogo prodotti carnei e ittici). Al fine di distinguere gli elementi del campione con una dieta riconducibile a quella di matrice vegetariana, sono state utilizzate le informazioni presenti nel dataset riguardanti le abitudini di consumo di carne o pesce. In particolare, è stata fatta la seguente approssimazione: un soggetto si considera vegetariano se ha scelto sempre l'opzione "mai" nelle domande relative al consumo di carne o pesce. Filtrando il dataset secondo questa condizione, è risultato che la percentuale di vegetariani presenti sul campione totale è del 3.5 % circa - una percentuale piccola ma di certo non trascurabile. Operativamente, è stato utilizzato il codice seguente:

```
# calcoliamo il numero di vegetariani, ovvero quanti hanno 5 in tutte le colonne che riguardano consumo di carne o pesce
cols <- c("SALUMI", "POLLO", "CROV", "OMIALE", "PESCE")
n_vege <- sum(cply(df_23[, cols, with = FALSE], 1, function(x) all(x == "mai", na.rm = TRUE)))
n_tot <- nrow(df_23)
perc_vege <- n_vege/n_tot * 100
perc_vege # 3.554 %
df_23$VEGE <- ifelse(
  df_23$CROV == "mai" &
  df_23$PESCE == "mai" &
  df_23$SALUMI == "mai" &
  df_23$POLLO == "mai" &
  df_23$OMIALE == "mai",
  1, 0
)
df_23$VEGE <- as.factor(df_23$VEGE)
levels(df_23$VEGE) <- c("non-vege",
                        "vegetariano")
```

Figura 12: Codice di creazione della variabile *VEGE*

Il risultato indica che circa il 3,5% del campione è classificabile come vegetariano: tale percentuale è conforme alle recenti statistiche nazionali sui regimi alimentari restrittivi.

Nel quadro delle diete prive di carne e pesce, il veganismo può essere considerato una forma più restrittiva del vegetarianismo, in quanto esclude non solo i prodotti animali ma anche tutti i loro derivati. Volendo individuare anche la percentuale di soggetti approssimabili a "vegani" all'interno del dataset, occorre estendere l'analisi anche ad alimenti che provengono dall'animale, pur non rappresentando l'animale stesso. A tal proposito, nella sezione alimentare il questionario presenta domande dirette anche ad appurare le frequenze di consumo di latte, uova e formaggi.




Figura 13: Distribuzione delle frequenze per le variabili latte, formaggi e uova

Mentre per i formaggi e le uova la distribuzione si allinea maggiormente a quelle riscontrate in precedenza per gli altri alimenti, il latte si dimostra caratterizzato da particolari frequenze di consumo. Quest'ultimo presenta il suo picco in "una volta al giorno", probabilmente riconducibile al suo ruolo centrale nella colazione italiana; allo stesso tempo, tuttavia, riporta livelli moderati per la classe "mai", indicando una maggiore eterogeneità nelle abitudini degli intervistati. Questo suggerisce che il latte sia un alimento più polarizzante: alcuni lo consumano frequentemente, altri lo evitano del tutto. Ad aumentare la popolosità di quest'ultimo caso contribuisce, presumibilmente, una possibile intolleranza al lattosio o differenze nel tipo di colazione, dal momento che si tratta di un alimento strettamente legato al primo pasto della giornata.

Al contrario, il consumo di formaggi risulta più centrato nel valore "qualche/settimana" con un picco marcato, mentre le modalità estreme (">1/giorno" e "mai") sono meno rappresentate. La distribuzione è quindi più compatta e indica che i formaggi costituiscono un alimento consumato con cadenza tipicamente moderata e regolare da gran parte del campione.

Le uova presentano una distribuzione simile a quella dei formaggi, ma con una maggiore asimmetria: la quota della categoria “mai” risulta più consistente rispetto agli altri due alimenti. Questo riflette una presenza più pronunciata di intervistati che limitano fortemente o evitano il consumo di uova, probabilmente per preferenze personali o per considerazioni nutrizionali.

Una volta filtrato il dataset rispetto agli intervistati che hanno riferito di non consumare nessuno degli alimenti sopracitati, la percentuale di vegani sul totale del campione è risultata pari al 2.9 % circa, sottolineando come un’ampia porzione della popolazione che sceglie di sposare i principi della dieta vegetariana, decide anche di abbracciare la sua declinazione più estrema, che rinuncia ad ogni tipo di alimento che sia di derivazione animale.

5 Analisi delle associazioni tra variabili

L'obiettivo di questa sezione è analizzare se le abitudini alimentari del campione, in particolare il consumo di vegetali, siano associate a caratteristiche socio-demografiche, come il grado di istruzione, la zona di residenza, il sesso e l'età. Poiché le variabili considerate nell'analisi sono prevalentemente categoriali e non soddisfano le assunzioni richieste dai test parametrici, la valutazione delle associazioni è stata condotta mediante test non parametrici, in particolare il test del chi-quadro di indipendenza, utilizzato per determinare se esiste una relazione statisticamente significativa tra due variabili qualitative.

5.1 Livello di istruzione e consumo di verdure

Per esaminare se il consumo di verdure differisce in relazione al livello di istruzione, è stata creata una tabella di contingenza per le due variabili e successivamente è stato eseguito il test del chi-quadro di indipendenza.

Le percentuali per riga indicano chiaramente che le categorie con un livello di istruzione più alto (in particolare laurea e diploma) hanno una maggiore concentrazione nel comportamento di consumo più frequente (" $>1/\text{giorno}$ "), mentre i livelli di istruzione inferiori (elementare/nessuno e medie) sono sovrarappresentati nelle categorie di consumo meno frequente (" $<1/\text{sett}$ " e "mai") e sottorappresentati nelle abitudini opposte. Questo schema descrittivo indica una prima possibile connessione tra educazione e abitudini alimentari. Il test del chi-quadro avvalora questa osservazione ($\chi^2 = 362.09$, $df = 16$, $p < 2.22 \times 10^{-16}$), segnalando che le due variabili non sono autonome. La significatività statistica, però, deve essere interpretata con attenzione: il valore della V di Cramer (circa 0.048) è piuttosto basso, indicando che l'associazione, sebbene esista, è di scarsa intensità.

I risultati vengono ulteriormente chiariti dall'*association plot*. Nelle celle evidenziate in blu si notano le combinazioni in cui la frequenza osservata supera quella attesa in una situazione di indipendenza: in particolare, gli individui laureati mostrano un surplus nelle categorie " $>1/\text{giorno}$ " e " $1/\text{giorno}$ ". Al contrario, le celle in rosso segnalano frequenze sotto le attese: i laureati appaiono scarsi nelle categorie di consumo più occasionale, mentre le categorie elementare/nessuno e medie evidenziano un surplus nelle modalità "mai" e " $<1/\text{sett}$ ".

Il grafico dei residui mostra visivamente questi schemi.




Figura 14: *Association plot* - istruzione vs consumo di verdure

5.1.1 Regione di residenza e consumo di verdure

L'analisi del legame tra area di residenza e frequenza di consumo di verdure mostra differenze territoriali piuttosto evidenti. La tabella di contingenza evidenzia una distribuzione non uniforme e il test del chi-quadro conferma un'associazione molto significativa ($\chi^2 = 1376.9$, $df = 76$, $p < 2.22 \times 10^{-16}$). L'intensità del legame, calcolata attraverso la V di Cramer (del valore di circa 0.09), risulta però debole, indicando che la regione condiziona il comportamento alimentare, ma solamente in parte.

Nell'*association plot* notiamo che le regioni che segnalano consumi più frequenti sono quelle del Nord Italia (e anche alcune del centro come le Marche). Al contrario, i residui notevolmente negativi si trovano principalmente nel Sud Italia, in particolar modo in Sicilia, Campania, Puglia e Molise. In figura sono mostrati i risultati appena analizzati.




Figura 15: *Association plot* - regione vs consumo di verdure

5.1.2 Sesso e consumo di verdure

L'associazione tra sesso e frequenza di consumo di verdure risulta altamente significativa secondo il test del chi-quadro ($\chi^2 = 468.76$, $df = 4$, $p < 2.22 \times 10^{-16}$). Il valore della V di Cramer (circa 0.108) indica un'associazione debole, sebbene più marcata rispetto a quella osservata per istruzione e regione. Ciò suggerisce che il sesso sia un fattore più rilevante nel differenziare le abitudini alimentari relative al consumo di verdure.

L'analisi dei residui di Pearson, mostrati nell'*association plot*, consente di comprendere approfonditamente la direzione delle associazioni. Le celle riguardanti le donne (categoria 2) evidenziano residui positivi molto elevati nelle categorie di consumo più comuni, in particolare “>1 volta al giorno” e “1 volta al giorno”. Questo segnala che le donne mangiano verdure più frequentemente di quanto ci si aspetterebbe ipotizzando indipendenza. Invece, gli uomini (categoria 1) mostrano residui nettamente negativi nelle stesse categorie, indicativo della loro sottorappresentazione tra i consumatori regolari. In sintesi, le donne dimostrano una maggiore propensione a consumare regolarmente verdure, mentre gli uomini tendono a mantenere un consumo sporadico o insufficiente. L'associazione, sebbene non sia forte in senso assoluto, risulta statisticamente solida e indica variazioni sistematiche nelle abitudini alimentari tra i due generi.




Figura 16: *Association plot* - sesso vs consumo di verdure

6 Analisi delle serie temporali e pattern di crescita

6.1 BMI e analisi delle variazioni nella distribuzione dello stato ponderale del campione

Il *Body Mass Index* (BMI) è l'indicatore standard impiegato a livello globale per esaminare lo stato ponderale della popolazione, dove per stato ponderale si intende la classificazione degli individui in categorie di peso corporeo sulla base del suddetto indicatore. Secondo la definizione riportata da Eurostat e basata sulle linee guida dell'Organizzazione Mondiale della Sanità (OMS), il BMI è calcolato come rapporto tra il peso del soggetto (in chilogrammi) e il quadrato della sua altezza (in metri).

L'OMS distingue le persone sulla base del valore di BMI in:

- **Sottopeso** ($\text{BMI} < 18.5$)
- **Normopeso** (BMI compreso tra 18.5 e 25)
- **Sovrappeso** ($\text{BMI} > 25$)
- **Obeso** ($\text{BMI} > 30$)

Eurostat evidenzia come l'aumento continuo delle percentuali di individui in sovrappeso o obesi in Europa costituisce uno dei principali fattori di rischio per numerose malattie, e proprio per questo viene costantemente monitorato.




Figura 17: Distribuzione della percentuale europea di individui in sovrappeso con età maggiore di 16 anni aggiornata al 2022, *Eurostat*

Nell'infografica in figura, è possibile osservare che la popolazione italiana si distingue per una percentuale di individui sovrappeso minore rispetto agli altri paesi di cui si hanno a disposizione i dati.

A tal proposito, l'obiettivo di questa sezione è quello di valutare l'andamento della percentuale di individui in sovrappeso e obesi secondo l'indice BMI in Italia, in un intervallo di tempo compreso tra il 2013 e il 2023, e di determinare, di conseguenza, l'esistenza di un trend di cambiamento rilevante. **Inoltre, si vuole esaminare la presenza di una relazione tra lo stato ponderale associato al BMI e il consumo di verdure/dieta vegetariana**

6.1.1 Analisi descrittiva della variabile BMI

Per cominciare, è bene descrivere preliminarmente la natura della variabile **BMI** rilevata dal questionario per il 2023.

Nel dataset ISTAT "Aspetti della vita quotidiana", il BMI è presentato non come valore numerico continuo, ma già suddiviso in categorie qualitative, con una codifica che ricorda quella europea. La variabile BMI presenta quattro modalità: sottopeso, normopeso, sovrappeso, obeso. Pertanto, si tratta di una variabile categorica ordinale che può unicamente essere analizzata mediante distribuzioni di frequenza e misure di associazione con altre variabili qualitative. Il Body Mass Index è significativo solo per persone adulte, perciò nel dataset è un valore

associato unicamente agli intervistati maggiorenni ed, inoltre, è stato osservato che la variabile non presenta valori mancanti.

	ANNO	tot	bmi_na	perc_na
	<dbl>	<int>	<int>	<dbl>
df_unico %>%	1 2014	37537	0	0
filter(ETAMi > 6) %>%	2 2015	37825	0	0
group_by(ANNO) %>%	3 2016	36391	0	0
summarise(	4 2017	41100	0	0
tot = n(),	5 2018	37391	0	0
bmi_na = sum(is.na(BMI)),	6 2019	38378	0	0
perc_na = bmi_na / tot * 100,	7 2020	36328	0	0
.groups = "drop"	8 2021	39140	0	0
)	9 2022	35916	0	0
	10 2023	35681	0	0

Figura 18: Verifica della presenza di NA per la variabile **BMI**

Possiamo visualizzare la distribuzione della variabile nel 2023 tramite il seguente barplot:




Figura 19: Distribuzione della variabile **BMI** per la popolazione maggiore di 18 anni

Il gruppo più numeroso è quello dei normopeso (50,3% sul totale dei maggiorenni), seguito dalla categoria dei sovrappeso, con un peso anch'essa molto consistente (circa il 34,4%). Le persone obese sono poco meno del 12% del campione

maggiormente, mentre la categoria meno popolosa è quella dei sottopeso, che rappresentano meno del 4% del totale. La distribuzione è piuttosto sbilanciata verso le modalità centrali: questo pattern è coerente con quanto osservato nei principali rapporti Eurostat. Infatti, la proporzione di individui sovrappeso nel dataset sembra collocarsi in un intervallo plausibilmente vicino a quello europeo, confermando la tendenza strutturale a un'elevata presenza di soggetti con BMI maggiore di 25.

6.1.2 Serie temporale del BMI

Al fine di analizzare l'andamento dell'indice BMI nel tempo, e in particolare della percentuale di individui in sovrappeso e obesi, è stato composto un unico dataset che contenesse tutte le unità statistiche corrispondenti ai partecipanti dei questionari somministrati tra il 2013 e il 2023, di cui sono state opportunamente conservate soltanto le colonne relative a sesso ed età del campione, anno di rilevazione, e BMI. Successivamente, è stato possibile calcolare due serie temporali, per valutare l'andamento del BMI rispetto al sesso del campione e rispetto all'età. Si ritiene necessario precisare che le serie temporali sono state analizzate in forma di data frame, mantenendo l'anno come indice temporale. Questa scelta consente una maggiore flessibilità nell'analisi comparativa tra gruppi e risulta adeguata agli obiettivi descrittivi del lavoro: infatti, l'indisponibilità di un orizzonte temporale sufficientemente ampio ha reso superflua la trasformazione della tabella in un oggetto *time series*, maggiormente adatto ad operazioni di decomposizione della serie, previsione (*forecasting*) e modellazione dinamica.

La prima serie temporale permette di considerare la variabilità del BMI dovuta al sesso dell'individuo.

ANNO	prev_sovrappeso_M	prev_obesi_M	prev_sovrappeso_F	prev_obesi_F
<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
2013	44.0	11.8	28.3	9.51
2014	44.8	11.3	28.7	10.0
2015	44.1	11.2	27.6	9.39
2016	44.7	11.5	27.9	10.2
2017	43.0	11.9	28.4	9.35
2018	44.0	12.2	28.3	9.87
2019	43.2	11.9	28.7	10.5
2020	44.4	12.5	28.7	10.6
2021	42.7	13.4	27.9	11.5
2022	42.9	12.8	28.3	10.7
2023	41.9	13.1	27.6	10.7

Figura 20: Serie storica della percentuale di sovrappeso e obesi rispetto al sesso




Figura 21: Curve della percentuale di sovrappeso e obesi differenziate per genere

La tabella della serie storica, letta congiuntamente al grafico, consente di osservare in modo chiaro l'evoluzione temporale delle prevalenze di sovrappeso e obesità nella popolazione adulta italiana, distinguendo per sesso. Nel periodo 2013–2023 emergono differenze di genere nette e persistenti, che il grafico rende immediatamente visibili. In particolare, il sovrappeso risulta costantemente più diffuso tra gli uomini, con valori sempre superiori al 40%, mentre tra le donne si colloca stabilmente intorno al 28%. Per entrambi i sessi il sovrappeso mostra oscillazioni contenute nel tempo, senza un trend di crescita marcato; nel caso maschile si osserva anzi una lieve tendenza alla diminuzione negli anni più recenti. Per quanto riguarda l'obesità, il grafico evidenzia invece una dinamica crescente nel corso del periodo analizzato. Tra gli uomini la prevalenza aumenta progressivamente, passando da valori prossimi all'11–12% nei primi anni della serie a livelli superiori al 13% negli anni più recenti. Anche tra le donne si osserva un incremento dell'obesità, seppur più moderato, con una crescita graduale fino al 2021 e una successiva fase di sostanziale stabilizzazione. Nel complesso, la lettura integrata di tabella e grafico suggerisce una dinamica di lungo periodo caratterizzata da una sostanziale stabilità del sovrappeso e da un trend di crescita graduale dell'obesità, più marcato nella popolazione maschile, evidenziando un possibile spostamento verso forme più gravi di eccesso ponderale.

Tabella 4: Statistiche riassuntive e dinamica temporale della prevalenza di sovrappeso e obesità per sesso (2013–2023)

Sesso	Stato	Media	Mediana	Min	Max	SD	IQR	Variazione assoluta	Crescita annua
Femmine	Obesi	10.2	10.2	9.35	11.5	0.68	1.01	+1.24	+0.12
Femmine	Sovrappeso	28.2	28.3	27.6	28.7	0.41	0.63	−0.73	−0.07
Maschi	Obesi	12.1	11.9	11.2	13.4	0.73	1.02	+1.32	+0.13
Maschi	Sovrappeso	43.6	44.0	41.9	44.8	0.92	1.31	−2.06	−0.21

La tabella dei valori riassuntivi riassume l’andamento delle prevalenze di sovrappeso e obesità nel periodo 2013–2023. I valori medi mostrano chiaramente un divario tra uomini e donne: il sovrappeso è più frequente tra gli uomini rispetto alle donne e anche l’obesità presenta livelli leggermente più elevati nella popolazione maschile. La forte somiglianza tra media e mediana indica che i valori sono abbastanza stabili nel tempo e che non vi sono anni particolarmente anomali che influenzino i risultati. Anche le misure di variabilità risultano contenute: la deviazione standard e l’intervallo interquartile (IQR) - differenza tra il terzo e il primo quartile - mostrano oscillazioni limitate nel tempo, soprattutto per il sovrappeso femminile, mentre una variabilità leggermente maggiore si osserva nel sovrappeso maschile e nell’obesità.

L’analisi della variazione complessiva nel periodo evidenzia dinamiche differenziate tra le due condizioni. In particolare, l’obesità mostra un aumento netto sia tra le donne sia tra gli uomini, mentre il sovrappeso registra una riduzione complessiva, più marcata nella popolazione maschile. Coerentemente, i valori della crescita media annua risultano positivi per l’obesità e negativi per il sovrappeso, suggerendo una possibile evoluzione verso forme più gravi di eccesso ponderale nel corso del periodo analizzato.

Nel complesso, la tabella descrive una situazione caratterizzata da livelli medi relativamente stabili, bassa variabilità temporale e segnali di peggioramento concentrati sull’obesità, in particolare tra gli uomini, confermando l’importanza di analizzare separatamente le diverse componenti dello stato ponderale.

Relativamente alla seconda serie temporale, sono state considerate due classi di età idonee a rappresentare due fasi del ciclo di vita particolarmente distinte e interessanti da comparare; ovvero, una fascia d’età compresa tra i 18 e i 34 anni, che si contrappone alla fascia d’età che va dai 45 ai 54 anni. Di seguito un’analisi atta a descrivere l’andamento dello stato ponderale delle suddette categorie.

ANNO	prev_sovrappeso_18_34	prev_obesi_18_34	prev_sovrappeso_45_54	prev_obesi_45_54
<int>	<dbl>	<dbl>	<dbl>	<dbl>
2013	20.1	4.18	39.2	10.7
2014	21.0	3.63	43.2	14.6
2015	19.6	3.69	41.8	14.0
2016	20.6	4.11	43.4	13.5
2017	20.0	4.26	41.1	13.6
2018	21.4	4.60	42.5	14.3
2019	21.0	4.98	40.5	14.4
2020	21.7	5.24	42.4	13.9
2021	20.1	5.37	39.3	14.1
2022	20.9	5.17	39.9	13.9
2023	20.2	5.97	39.0	14.1

Figura 22: Serie storica della percentuale di sovrappeso e obesi rispetto all'età




Figura 23: Curve della percentuale di sovrappeso e obesi differenziate per età

La tabella e il grafico mostrano congiuntamente l'andamento della prevalenza di sovrappeso e obesità nelle classi di età 18–34 anni e 45–54 anni nel periodo 2013–2023. Dai dati emerge una chiara differenza legata all'età, con livelli di eccesso ponderale sistematicamente più elevati nella fascia 45–54 anni rispetto a quella più giovane. In particolare, il sovrappeso si mantiene intorno al 20% tra i 18–34 anni, mentre nella classe 45–54 anni raggiunge valori prossimi al 40%, evidenziando un marcato gradiente anagrafico.

Anche per l'obesità si osserva una dinamica differenziata: nella popolazione più giovane la prevalenza resta contenuta, pur mostrando un lento aumento nel tempo, mentre nella fascia 45–54 anni i livelli risultano significativamente più alti, con valori superiori al 13% per gran parte del periodo analizzato.

Dal punto di vista temporale, entrambe le classi di età presentano oscillazioni limitate, suggerendo una sostanziale stabilità del sovrappeso e una crescita graduale dell'obesità, più evidente nella classe di età più avanzata.

Nel complesso, la lettura congiunta di tabella e grafico indica che l'età rappresenta un fattore fortemente associato allo stato ponderale: l'eccesso di peso risulta più diffuso nelle fasce adulte centrali e tende a manifestarsi con maggiore intensità sotto forma di obesità, confermando l'importanza di considerare il profilo anagrafico nell'analisi delle dinamiche del BMI.

Tabella 5: Statistiche riassuntive e dinamica temporale della prevalenza di sovrappeso e obesità per classe di età (2013–2023)

Classe d'età	Stato	Media	Mediana	Min	Max	SD	Var	IQR	Variazione assoluta	Crescita annua
18–34 anni	Obesi	4.65	4.60	3.63	5.97	0.749	0.561	1.06	1.78	0.178
18–34 anni	Sovrappeso	20.6	20.6	19.6	21.7	0.660	0.435	0.930	0.165	0.0165
45–54 anni	Obesi	13.7	14.0	10.7	14.6	1.06	1.13	0.484	3.47	0.347
45–54 anni	Sovrappeso	41.1	41.1	39.0	43.4	1.63	2.66	2.82	−0.150	−0.0150

La tabella riporta le principali statistiche descrittive e dinamiche della prevalenza di sovrappeso e obesità nelle due classi di età considerate (18–34 anni e 45–54 anni) nel periodo 2013–2023. Dai valori medi emerge una netta differenza tra le classi di età: nella fascia 18–34 anni le percentuali risultano più contenute, soprattutto per l'obesità, mentre nella classe 45–54 anni sia il sovrappeso sia l'obesità presentano livelli medi sensibilmente più elevati. Questo indica un aumento dello stato ponderale critico con l'avanzare dell'età.

Il confronto tra media e mediana mostra valori molto simili in tutte le combinazioni di classe d'età e stato ponderale, suggerendo una distribuzione stabile e priva di forti asimmetrie nel tempo. Anche l'escursione tra valori minimi e massimi risulta relativamente contenuta, in particolare nella fascia più giovane, mentre nella classe 45–54 anni si osserva una variabilità leggermente maggiore. Le misure di dispersione (deviazione standard, varianza e intervallo interquartile) confermano questa lettura: la variabilità è più ridotta tra i 18–34 anni, mentre aumenta nella fascia 45–54 anni, soprattutto per il sovrappeso. Ciò indica che, oltre a livelli medi più elevati, nelle età intermedie la prevalenza mostra fluttuazioni temporali più marcate.

Dal punto di vista dinamico, la variazione assoluta e il tasso di crescita media annua evidenziano una tendenza all'aumento dell'obesità in entrambe le classi di età, più pronunciata nella fascia 45–54 anni. Al contrario, il sovrappeso appare sostanzialmente stabile o in lieve diminuzione nel tempo, suggerendo una possibile traslazione verso forme più gravi di eccesso ponderale, come anche riscontrato in precedenza.

6.1.3 Associazione tra BMI e abitudini vegetariane

Per esaminare la possibile connessione tra lo stato ponderale e l'adesione o meno al vegetarianismo, è stata costruita una tabella di contingenza che mette in relazione le variabili **BMI** e **VEGE** per il 2023, necessaria all'applicazione del test del Chi-quadrato. Il risultato evidenzia un'associazione statisticamente significativa ($\chi^2 = 71.289$, $df = 3$, $p < 2.3 \times 10^{-15}$), suggerendo che la distribuzione del BMI varia in modo non casuale tra vegetariani e non vegetariani. Verosimilmente, però, se si calcola la V di Kramer, una misura standardizzata dell'intensità dell'associazione e indipendente dalla dimensione del campione, calcolata a partire dal χ^2 , si ottiene un valore molto basso, 0.045, che suggerisce un'intensità molto debole tra le due variabili: questo risultato indica che, pur in presenza di un'associazione statisticamente significativa, la variabile alimentare considerata contribuisce solo marginalmente a spiegare la distribuzione del BMI, il quale dipenderà da altri fattori come, si ipotizza, età, attività fisica o istruzione.

Al fine di visualizzare più chiaramente l'associazione tra le due variabili categoriali, è stato utilizzato un *mosaic plot*, rappresentato di seguito:




Figura 24: *Mosaic plot* per le variabili **BMI** e **VEGE**

La dimensione dei rettangoli evidenzia chiaramente uno sbilanciamento tra la classe dei vegetariani e non vegetariani, come rilevato anche in precedenza. Le celle relative ai non vegetetiani presentano residui prossimi allo zero (colorazione grigia). Al contrario, i blocchi blu e rossi, pur di dimensioni ridotte, corrispondono alle celle in cui i vegetariani risultano sovra o sotto rappresentati rispetto

all'atteso: in particolare, il grafico mostra una maggiore concentrazione di individui normopeso e una minore presenza di sovrappeso e obesità tra i vegetariani rispetto a quanto atteso.

Per quanto riguarda il campione in esame, solo lo 0.6 % della popolazione appartenente alla categoria degli obesi risulta essere vegetariano, e circa lo stesso dato si può riscontrare per i sovrappeso. Analogamente, osservando la distribuzione dei vegetariani, è possibile osservare che la percentuale di obesi ammonta al 7 %, a differenza dell'11 % rilevato sull'intero campione.

7 Metodi di riduzione della dimensionalità

7.1 Analisi delle componenti multiple (MCA)

Al fine di esplorare in modo congiunto le relazioni tra le principali variabili qualitative relative ai comportamenti alimentari, è stata condotta un'Analisi delle Corrispondenze Multiple (*Multiple Component Analysis*, MCA) sul dataset oggetto di studio. L'MCA consente di individuare le dimensioni latenti che organizzano i comportamenti alimentari del campione, così da ridurre la dimensionalità del dataset. Gli assi (dimensioni) della MCA sono costruiti in modo da massimizzare la varianza spiegata e riassumere l'informazione contenuta nelle variabili originali.

In un primo momento, l'analisi è stata limitata agli individui tra i 18 e i 34 anni, e poi la stessa è stata ripetuta per la fascia tra i 45 e i 54 anni, così da poter comparare i risultati ottenuti.

7.1.1 Analisi delle corrispondenze multiple per gli individui tra i 18 e i 34 anni

Preliminarmente il dataset è stato opportunamente riorganizzato selezionando unicamente variabili categoriali idonee alla MCA, con particolare riferimento alle frequenze di consumo di specifici gruppi alimentari (verdure, carne bovina, pollame, salumi, ...). Alcune variabili di natura socio-demografica (livello di istruzione, regione di residenza, BMI, ...) sono state invece incluse come variabili supplementari, al fine di valutarne l'associazione con le strutture latenti emerse senza influenzare la costruzione dello spazio fattoriale.

La figura 25 rappresenta la proiezione delle variabili quantitative supplementari sul piano fattoriale definito dalle prime due dimensioni della MCA. In questo caso, l'unica variabile quantitativa supplementare considerata è NCOMP (numero di componenti familiari). Il cerchio rappresenta il cerchio delle correlazioni: quanto più una variabile è lontana dall'origine e vicina alla circonferenza, tanto maggiore è la sua correlazione con almeno una delle dimensioni. Al contrario, una variabile posizionata in prossimità dell'origine indica una correlazione molto debole o nulla con le dimensioni considerate. È proprio questo il nostro caso: NCOMP risulta collocata in prossimità dell'origine del piano fattoriale, con coordinate prossime allo zero sia lungo la Dimensione 1, che spiega il 10.17% dell'inerzia totale, sia lungo la Dimensione 2, che ne spiega l'8.75%. Dunque,

NCOMP non è associata in modo significativo alle strutture latenti individuate dalle prime due dimensioni della MCA e la sua variabilità non segue i principali gradienti di comportamento alimentare emersi dall'analisi. In pratica, NCOMP non contribuisce all'interpretazione del piano fattoriale principale.




Figura 25: Cerchio delle correlazioni per la variabile quantitativa supplementare NCOMP

Se volessimo invece rappresentare gli individui del campione sulle prime due dimensioni otterremo il grafico in Figura 26. La distribuzione dei punti mostra una forte concentrazione attorno all'origine, indicativa della presenza di un ampio numero di individui con profili di consumo alimentare poco caratterizzanti rispetto alle due dimensioni. Allo stesso tempo, si osserva una struttura allungata lungo la Dim 1, con alcuni profili che dunque si distanziano considerevolmente dal centro, ma anche una dispersione lungo la DIM 2, anche se più contenuta, ma che comunque consente di distinguere sottogruppi di individui che si differenziano ulteriormente all'interno dei profili definiti dalla prima dimensione.

L'analisi è proseguita proiettando le variabili attive sulle prime due dimensioni, come mostrato in figura 27. La prima dimensione tende ad isolare i profili alimentari più netti e sbilanciati, cioè caratterizzati da un consumo molto elevato di carne, pesce e legumi (superiore ad una volta al giorno), rispetto ai profili più moderati e bilanciati che si collocano in prossimità dell'origine. La seconda dimensione, invece, mostra una struttura oppositiva più netta e interpretabile, distinguendo chiaramente gli individui associati a un consumo frequente di prodotti animali, collocati nella parte alta del piano fattoriale, da quelli caratte-




Figura 26: Proiezione degli individui sul piano fattoriale della MCA

rizzati dall’astensione dal consumo di carne e pesce, collocati nella parte bassa. In pratica possiamo interpretare la Dim 2 come un asse di orientamento della dieta, che oppone da una parte modelli alimentari di tipo carnivoro e dall’altro modelli vegetariani o fortemente restrittivi rispetto ai prodotti di origine animale.




Figura 27: Proiezione delle variabili attive sul piano fattoriale della MCA

L'aggiunta delle variabili supplementari consente di arricchire l'interpretazione delle dimensioni senza alterarne la costruzione. Tali variabili (in verde nella Figura 30) si concentrano prevalentemente in prossimità dell'origine, segnalando una limitata capacità discriminante rispetto alle due dimensioni. Ciò indica che caratteristiche socio-demografiche come livello di istruzione, regione di residenza, o altre variabili di contesto non sono i principali fattori strutturanti delle differenze nei comportamenti alimentari. Fa eccezione la modalità "vegetariano", che si colloca in una posizione ben definita nella parte inferiore del piano, coerentemente con le modalità "mai" di consumo di carne e pesce. Questa collocazione rafforza l'interpretazione della seconda dimensione (Dim 2) come asse di opposizione tra un profilo carnivoro intenso e un profilo di rinuncia sistematica ai prodotti animali.

Figura 28: Proiezione delle variabili attive e supplementari sul piano fattoriale della MCA

Per quanto riguarda la prima, i valori di R^2 evidenziano un legame particolarmente forte con le variabili relative al consumo di prodotti di origine animale, in particolare carne bovina, carne suina, pollo, salumi e pesce. Le modalità

associate a consumi molto frequenti (superiori a una volta al giorno) presentano stime positive elevate, indicando una collocazione coerente sullo stesso lato della dimensione, mentre le modalità caratterizzate da consumi più contenuti o sporadici mostrano stime negative. Questo risultato conferma che la dimensione 1 discrimina soprattutto in base all'intensità e alla marcatezza dei comportamenti alimentari.

Anche per la seconda dimensione le variabili di consumo di carne e pesce presentano valori di R^2 elevati, ma assume particolare rilievo la variabile VEGE, che risulta fortemente associata all'asse. Le modalità “non-vege” e quelle corrispondenti a consumi molto frequenti di carne e pesce si collocano su un polo della dimensione, mentre le modalità “vegetariano” e “mai” per il consumo di carne e pesce presentano stime fortemente negative e si dispongono sul polo opposto. Dunque, si potrebbe concludere che la dimensione 2 discrimini fortemente i soggetti che non includono la carne e il pesce nella loro dieta da quelli che, al contrario, hanno l'abitudine di mangiarli anche più volte alla settimana.




Figura 29: Risultati di dimdesc per la fascia 18–34 anni

Possiamo inoltre rappresentare un grafico delle modalità colorato in base al coseno quadro, che consente di valutare la qualità della rappresentazione delle

singole categorie sul piano fattoriale. Le modalità con valori di $\cos^2$ elevati, evidenziate da tonalità calde, risultano ben spiegate dalle prime due dimensioni e sono pertanto quelle più rilevanti per l'interpretazione.




Figura 30: Mappa delle categorie nella MCA colorata per $\cos^2$

Per visualizzare la distribuzione dell'inerzia spiegata dalle diverse dimensioni eseguiamo uno *scree plot* (figura 36). Le prime quattro dimensioni presentano una quota di varianza relativamente più elevata, con la prima che spiega circa il 10,2% dell'inerzia totale e la seconda l'8,8%. A partire dalla quinta dimensione il contributo marginale di ciascun asse si riduce sensibilmente.




Figura 31: *Scree plot* delle dimensioni della MCA

Nell'Analisi delle Corrispondenze Multiple si calcolano anche gli autovalori per ciascuna dimensione, che rappresentano la corrispettiva quota di inerzia. Gli autovalori grezzi, però, tendono a sottostimare l'importanza delle prime dimensioni fattoriali a causa dell'elevato numero di modalità delle variabili qualitative. Per ovviare a questo limite, l'interpretazione dei risultati è stata condotta facendo riferimento alla correzione di Benzécri, che consente di isolare la quota

di inerzia effettivamente informativa. La correzione si basa sulla trasformazione degli autovalori grezzi λ_j secondo la seguente relazione:

$$\lambda_j^{(B)} = \frac{Q}{Q-1} \left(\lambda_j - \frac{1}{Q} \right)$$

dove Q rappresenta il numero di variabili attive considerate nell'analisi. Gli autovalori negativi risultanti dall'applicazione della formula vengono posti pari a zero, in quanto privi di significato interpretativo. L'applicazione della correzione di Benzécri nel presente studio evidenzia una forte concentrazione della varianza sulle prime 3 dimensioni fattoriali: la prima spiega circa il 30,6% della varianza corretta, la seconda contribuisce per circa il 24%, e con la terza la quota di varianza spiegata supera complessivamente il 74%.




Figura 32: Codice e relativo risultato per il calcolo degli autovalori corretti di Benzécri

7.1.2 Analisi delle corrispondenze multiple per gli individui tra i 45 e i 54 anni

Al fine di verificare se i risultati della precedente analisi variano al mutare della fase del ciclo di vita, l'Analisi delle Corrispondenze Multiple viene ora replicata limitando il campione alla fascia d'età 45-54 anni.

Il seguente grafico rappresenta la proiezione degli individui sul piano fattoriale

definito dalle prime due dimensioni. Anche in questo caso si osserva una forte concentrazione di individui in prossimità dell'origine. L'allungamento della nuvola, però, è più marcato nel quadrante in basso a destra, al contrario dell'altra fascia di età analizzata.




Figura 33: Proiezione degli individui sul piano fattoriale della MCA

Osservando il grafico delle modalità sul piano fattoriale, l'interpretazione delle prime due dimensioni risulta coerente con quella osservata nella fascia 18-34 anni. In particolare, la seconda dimensione continua a rappresentare l'opposizione tra profili alimentari a forte consumo di carne, pesce e legumi e profili caratterizzati da assenza di tali alimenti, ma la loro collocazione è opposta (i vegetariani sono posizionati lungo l'asse dei valori positivi anziché negativi).




Figura 34: Proiezione delle variabili attive e supplementari sul piano fattoriale della MCA

Al fine di rendere più leggibile l'interpretazione delle dimensioni emerse dall'Analisi delle Corrispondenze Multiple, sono stati calcolati anche in questo caso per tutte le variabili e le modalità i corrispondenti valori di R^2 ed *estimate*.




Figura 35: Risultati di dimdesc per la fascia 45–54 anni

Anche nella fascia 45-54 anni la prima dimensione fattoriale è dominata dall'intensità del consumo, con stime fortemente positive associate ai consumi quotidiani e stime negative alle modalità più “moderate”, in continuità con quanto osservato per i 18-34enni. La seconda dimensione contrappone anche in questo caso un modello vegetariano o di esclusione di carne e pesce a un modello fortemente carnivoro, sebbene il segno dell'asse risulti invertito rispetto ai più giovani, ma l'interpretazione sostanziale rimane invariata.

Anche in questo caso mostriamo il grafico delle modalità colorato in base ai corrispettivi valori del coseno quadro:




Figura 36: Mappa delle categorie nella MCA colorata per coseno quadrato

Dal confronto tra i risultati delle due analisi, è possibile concludere che tra la fascia 18–34 anni e quella 45–54 anni non esistono evidenti differenze sostanziali nella struttura delle prime dimensioni fattoriali.

8 Clustering gerarchico sulle componenti principali (HCPC)

L’analisi è stata ulteriormente approfondita applicando la procedura HCPC (*Hierarchical Clustering on Principal Components*), che combina l’Analisi delle Corrispondenze multiple con tecniche di clustering.

In particolare, l’HCPC opera in tre fasi:

1. utilizza le coordinate degli individui sulle componenti fattoriali della MCA
2. applica un clustering gerarchico agglomerativo, basato sul metodo di Ward, che minimizza la varianza intra-cluster
3. consolida la partizione finale mediante un algoritmo di tipo *k-means*

Il numero di cluster, se non viene fissato manualmente, è selezionato sulla base dei salti di inerzia osservati nel dendrogramma.

Relativamente all’MCA operata per la fascia di età 18-34 anni, l’applicazione iniziale della procedura HCPC ha individuato automaticamente cinque cluster distinti. Tuttavia, l’osservazione della distribuzione degli individui ha mostrato come alcuni di questi cluster presentassero profili molto simili e difficilmente distinguibili dal punto di vista interpretativo. Per questa ragione, al fine di ottenere una segmentazione più compatta, si è scelto di forzare il numero di

cluster a quattro (Figura 37), scartando l'ipotesi di una soluzione a tre cluster che, pur tecnicamente possibile, risultava eccessivamente semplificata.




Figura 37: Divisione in cluster degli individui nella fascia 18-34 anni

Il cluster nero raccoglie gli individui con coordinate prossime all'origine del piano fattoriale per entrambe le dimensioni, quindi di tutti i soggetti con comportamenti alimentari relativamente equilibrati, senza particolari sbilanciamenti: è il cluster del profilo "medio".

Il cluster rosso è invece caratterizzato da individui che si collocano leggermente a destra dell'origine lungo la dimensione 1 e in area positiva della dimensione 2, ma senza raggiungere valori estremi: sono gli individui con uno stile alimentare orientato al modello onnivoro tradizionale.

Il cluster che si sviluppa nella parte inferiore del piano (in verde) rappresenta gli individui con basso o nullo consumo di prodotti di origine animale: incarna un modello alimentare alternativo, ben definito e coerente, approssimabile agli schemi della dieta vegetariana.

Infine, il cluster blu è rappresentativo di tutti coloro che si collocano in posizione estrema lungo entrambe le dimensioni. È dunque caratterizzato da individui che hanno consumi molto frequenti di carne e pesce, e in generale hanno uno stile alimentare fortemente sbilanciato ed intensivo.

È necessario segnalare a margine che gli stessi risultati sono stati ottenuti applicando l'HCPC per i soggetti di età compresa tra 45 e i 54 anni: questo risultato suggerisce una certa omogeneità nella distribuzione degli stili alimentari tra queste fasce d'età, almeno per quanto riguarda il campione preso in esame.

9 Social media e Sentiment Analysis

9.1 Contesto della ricerca e obiettivi dell'analisi

Negli ultimi anni i social media sono diventati uno spazio centrale di produzione e circolazione del discorso pubblico, offrendo una fonte privilegiata per l'analisi delle opinioni, delle narrazioni e delle dinamiche di confronto su temi socialmente rilevanti. In questo contesto, la *sentiment analysis* e, più in generale, le tecniche di analisi testuale rappresentano strumenti fondamentali per studiare non solo l'orientamento emotivo dei contenuti, ma anche le strutture semantiche e le associazioni concettuali che emergono dal linguaggio utilizzato dagli utenti.

Il presente capitolo si propone di analizzare e confrontare il discorso relativo alla tematica vegana a partire da due dataset eterogenei, selezionati al fine di cogliere differenze e analogie tra contesti comunicativi diversi.

Il primo dataset è costituito da commenti pubblicati sotto un video Youtube di Vice, la rivista fondata in Canada che offre contenuti sulla cultura giovanile, la controcultura, la musica, la moda, le notizie e i documentari investigativi, spesso esplorando argomenti controversi o di nicchia. Il video è un'intervista a uomini e donne italiani, vegani e non, che discutono apertamente della tematica. Il secondo dataset è stato invece reperito tramite Kaggle e contiene una raccolta di articoli internazionali scritti sul tema del veganismo. A differenza dei commenti social, questo corpus riflette un contesto comunicativo più strutturato e informativo, nel quale il linguaggio tende a essere più formale, argomentativo e orientato alla trasmissione di contenuti tematici piuttosto che al confronto diretto.

L'obiettivo dell'analisi è duplice. Da un lato, si vuole mettere a confronto le opinioni degli italiani con lo stato attuale del dibattito a livello internazionale-quelle, per poter evidenziare eventuali divergenze. Dall'altro, si vuole applicare una serie di tecniche di analisi testuale al fine di verificare se e in che misura emergano differenze riconducibili alla diversa natura dei testi analizzati.

9.2 Analisi dei commenti social italiani

Il primo dataset analizzato è stato reperito tramite la piattaforma *Apify*, un servizio che consente l'estrazione di dati da fonti web e social media attraverso strumenti di *web scraping* configurabili.

```

> head(df)
# A tibble: 6 x 6
  author_name author_thumbnail text likes_count reply_count published_time_text
  <chr>        <chr>          <chr> <chr>      <chr>      <chr>
1 @VICE       https://yt3.ggp... "VIC... 155      41        5 anni fa
2 @mooneriks  https://yt3.ggp... "il ... 0        2        2 settimane fa
3 @flavioaradassao... https://yt3.ggp... "15:.. 0        3 settimane fa (no...
4 @leonardo240? https://yt3.ggp... "IL ... 0        1 mese fa
5 @TeodoroMacrin... https://yt3.ggp... "Usa... 0        1 mese fa
6 @FrancescoCompa... https://yt3.ggp... "L e... 1        2 mesi fa
> |

```

Figura 38: Struttura del dataset sui commenti italiani

Come mostra la figura 38, il dataset è composto da 2522 osservazioni, ciascuna caratterizzata dal testo del commento e da un insieme di metadati associati: l'username dell'autore, l'URL della sua immagine del profilo, il numero di like ricevuti, il numero di risposte e l'indicazione temporale relativa alla pubblicazione.

9.2.1 Preprocessing e analisi lessicale del corpus

L'analisi testuale consente di rappresentare il linguaggio in forma lessicale e testuale senza la necessità di una lettura diretta dei testi. Per poter lavorare su dati ad elevata eterogeneità lessicale, come nel nostro caso, è stato necessario applicare una procedura di normalizzazione, finalizzata a rendere il testo analizzabile in modo coerente. Il corpus, infatti, è stato sottoposto ad una serie di operazioni di pulizia: conversione in minuscolo, rimozione delle emoji, eliminazione dei caratteri non alfabetici, eliminazione degli spazi.

Una volta normalizzato il testo, si è proceduto alla tokenizzazione, ossia alla segmentazione del corpus in singole unità lessicali. A partire da queste, si è calcolato il numero di occorrenze totali delle parole e di forme lessicali distinte. Su questa base è stato calcolato il Type-Token Ratio (TTR), risultato pari al 12,37%, che misura il rapporto tra il numero di tipi e il numero totale di token. Tale valore indica una ricchezza lessicale relativamente contenuta, coerente con la natura dei commenti social, e in linea con la soglia massima consigliata per tale indicatore, pari al 20%.

L'analisi è proseguita con il calcolo delle parole più ricorrenti nel corpus, che sono risultate essere *vegani*, *carne*, *animali*, *essere*, *vegano* e *solo*, confermando la centralità del dibattito attorno alle scelte alimentari e al rapporto tra esseri umani e animali. Osservando proprio la frequenza delle parole, il linguista statunitense Zipf intuì l'esistenza di un rapporto tra tale frequenza e il rango della parola stessa. In particolare, la legge di Zipf afferma che frequenza e rango sono

inversamente proporzionali, anche se in realtà da studi successivi è emerso che è più appropriato esprimere la legge come $f \cdot r^a = c$ che, su scala logaritmica si esprime come $a \log(r) + \log(f) = c$, cioè come un'equazione di una retta in cui a indica la pendenza o la ricchezza del vocabolario, la quale, a sua volta, dipende dalla dimensione del testo. Nel presente lavoro la legge di Zipf è stata applicata al corpus dei commenti analizzati. I risultati (Figura 39) mostrano un andamento in scala logaritmica coerente con quanto appena illustrato.




Figura 39: La legge di Zipf applicata ai dati

L'estrazione delle parole chiave è stata effettuata tramite l'algoritmo RAKE (*Rapid Automatic Keyword Extraction*), una tecnica non supervisionata che consente di individuare automaticamente termini e frasi rilevanti all'interno di un corpus testuale senza fare ricorso a dizionari predefiniti. Il principio alla base di RAKE è che una parola chiave risulti tanto più rilevante quanto più compare frequentemente nel testo e quanto più è connessa ad altre parole all'interno delle frasi candidate.

Il grafico 40 mostra le prime 20 parole chiave individuate, ordinate in base al valore del RAKE *index*: emergono in particolare espressioni legate all'impatto ambientale, alla catena alimentare e al riscaldamento globale, indicando che il dibattito nei commenti non si limita alle scelte alimentari individuali, ma si estende a tematiche più ampie di tipo etico ed ecologico.




Figura 40: Keywords con RAKE *index* più alto

9.2.2 Analisi delle concordanze

L’analisi delle concordanze (*Concordance Analysis*) è stata utilizzata per approfondire il contesto semantico in cui compaiono alcune espressioni chiave all’interno dei commenti. La maggior parte delle espressioni analizzate sono state selezionate a partire dalle *keyword* individuate tramite l’algoritmo RAKE, privilegiando quelle caratterizzate da un valore di RAKE *index* più elevato, in quanto ritenute maggiormente rappresentative dei temi centrali del dibattito. In particolare, sono state considerate le espressioni *impatto ambientale*, *riscaldamento globale*, *catena alimentare*, *allevamento intensivo*, *essere vivente*, *oppressore umano*, *soldi e bibbia*.

L’analisi KWIC, che mostra le parole precedenti e successive a ciascuna espressione, evidenzia come tali termini vengano frequentemente inseriti all’interno di argomentazioni di tipo etico, ambientale e morale. Ad esempio, l’espressione “catena alimentare” compare spesso in frasi che sottolineano la posizione dominante dell’essere umano (“*da millenni siamo alla cima della catena alimentare*”), mentre “essere vivente” è utilizzata per rivendicare il diritto alla vita degli animali (“*diritto alla vita come qualsiasi altro essere vivente*”). Sempre sul tema etico si è parlato degli impatti dannosi degli allevamenti intensivi: “*L’allevamento intensivo oltre che inquinare fa vivere agli animali una vita miserabile*”, “*L’allevamento intensivo non è n’è ecologico n’è etico*”.

Se da una parte troviamo espressioni come le precedenti, che quindi sembrerebbero supportare la scelta di una dieta vegetariana/vegana, dall’altra sono state riscontrate anche numerose opinioni contrarie. Ad esempio, un utente si chiede

“perché deve per forza essere intensivo l'allevamento”, suggerendo dunque un consumo di carne e pesce ma consapevole. C'è chi invece parla di una scelta contronatura: “se anche gli animali ragionassero così non esisterebbe la catena alimentare”, “cos'è adesso i leoni si mettono a brucare l'erba”. Altri utenti invece non sono favorevoli per questioni economiche, infatti ricercando le parole precedenti e successive a “soldi” troviamo frasi come “non ho abbastanza soldi per essere vegana”, “gli alimenti bio e integrali che costano un sacco di soldi”. Infine, è stata riscontrata anche una componente significativa di utenti che si appellano alla religione per sostenere la propria tesi: “Dio disse di non uccidere ma se voi leggeste approfonditamente la bibbia trovereste scritto chiaramente che quel comandamento esclude totalmente gli animali”.

9.2.3 Wordcloud

A partire dal corpus normalizzato è stata costruita la matrice termini-documenti (TDM), una rappresentazione vettoriale del testo basata sul modello *bag of words*, che descrive ciascun documento attraverso le frequenze dei termini, prescindendo dall'ordine in cui compaiono. Nel presente lavoro è stato adottato uno schema di pesatura basato sulla frequenza assoluta dei termini, coerente con l'obiettivo di questa parte di analisi. Infatti, la TDM è stata utilizzata per calcolare la frequenza complessiva delle parole nel corpus per generare una *word cloud*, ovvero una rappresentazione visiva in cui la dimensione di ciascun termine è proporzionale alla sua frequenza di occorrenza.




Figura 41: Wordcloud dei commenti italiani

La *word cloud* ottenuta consente di cogliere in modo immediato i temi dominanti della discussione, offrendo una sintesi visiva del lessico più utilizzato nei

zione verso le tematiche etiche che, sostanzialmente assenti nei commenti più datati e invece predominanti nei più recenti.

9.2.4 Analisi delle associazioni

L’analisi delle associazioni è stata condotta al fine di esplorare le relazioni lessicali che emergono nel discorso attorno ad alcuni concetti chiave della tematica vegana. In particolare, è stata utilizzata la funzione `findAssocs()` del pacchetto `tm`. Tale funzione calcola, per ciascun termine del corpus, una misura di correlazione basata sulle frequenze di occorrenza nei documenti, restituendo i termini che tendono a co-occorrere con una parola target all’interno degli stessi testi. In pratica, prese due parole, misura quanto spesso esse compaiono negli stessi documenti, rispetto a quanto ci si aspetterebbe se fossero indipendenti. Valori alti di questo indice indicano che i due termini vengono usati insieme in modo sistematico dagli utenti.

Nel caso della parola “animali”, le associazioni più rilevanti (Figura 43) includono termini come *oppressione*, *ingiuste*, *difesa* e *maltrattamenti*, evidenziando come il discorso nei commenti sia fortemente orientato verso una cornice etica e morale, nella quale gli animali vengono frequentemente rappresentati come soggetti di ingiustizia o vittime di pratiche oppressive.




Figura 43: Plot delle associazioni con la parola “animali”

Si è successivamente analizzata la parola “insostenibile” (Figura 44), per la quale emergono associazioni con termini quali *energia*, *colture*, *troppi* e *viviamo*. Queste co-occorrenze rimandano a un discorso centrato sui limiti ambientali e sulle conseguenze sistemiche dei modelli produttivi e di consumo, confermando come il veganismo venga spesso inquadrato, nei commenti, non solo come scelta individuale ma come risposta a problematiche di carattere globale.

Alla luce dei risultati dell’analisi delle concordanze, in cui era emersa anche una dimensione economica del dibattito, ci si sarebbe potuti attendere la presenza di termini riconducibili a tale ambito, che tuttavia non risultano associati in questa analisi.




Figura 44: Plot delle associazioni con la parola “insostenibile”

Infine, considerando la parola *vegani*, le associazioni selezionate (Figura 45) mostrano un dibattito fortemente polarizzato. Accanto a termini come *vivisezione*, *sacrifica* e *umanizzano*, che richiamano temi etici e morali, compaiono anche riferimenti a questioni non direttamente collegate all’alimentazione, come *anti-vax* e *proaborto*. Questo suggerisce che il veganismo venga talvolta collegato a posizioni ideologiche più ampie, attraverso semplificazioni ed etichette.




Figura 45: Plot delle associazioni con la parola “vegani”

È bene sottolineare che valori elevati dell’indice di associazione indicano che i termini tendono a comparire congiuntamente negli stessi commenti, riflettendo una prossimità discorsiva piuttosto che una relazione semantica in senso stretto. Nei commenti social, caratterizzati da testi brevi e da un vocabolario ripetiti-

vo, tali associazioni possono risultare accentuate, soprattutto per termini poco frequenti ma sistematicamente co-occorrenti con la parola target.

9.2.5 Sentiment Analysis

L'analisi del sentiment è il processo attraverso il quale si individua e si classifica l'orientamento emotivo espresso in un testo, con l'obiettivo di cogliere l'atteggiamento dell'autore nei confronti di un determinato tema. Può essere considerata un problema di classificazione, in cui i documenti vengono assegnati a categorie di polarità, tipicamente positiva, negativa o neutra, oppure a classi emotive più articolate. Per i commenti in esame è stato adottato un approccio lessicale *dictionary-based*, che si fonda sull'utilizzo di un dizionario di *sentiment* in cui le parole sono annotate con una polarità predefinita. In particolare, è stata utilizzata la libreria **TextWiller**, uno dei pochi pacchetti R specificamente progettati per il *text mining* in lingua italiana.




Figura 46: Distribuzione complessiva del *sentiment* nei commenti su Youtube

L'analisi del sentiment sull'intero corpus di commenti mostra una distribuzione relativamente equilibrata, con una leggera prevalenza del *sentiment* negativo (36,5%), seguito da quello neutro (33,4%) e, infine, da quello positivo (30,2%). Questa distribuzione suggerisce che il tema del veganismo tende a generare reazioni fortemente polarizzate: accanto a commenti informativi o descrittivi, emerge una componente critica significativa, che riflette il carattere controverso dell'argomento nel dibattito pubblico online. Il sentiment positivo è comunque presente, con una percentuale non trascurabile.

Per approfondire l'evoluzione del dibattito nel tempo, il sentiment è stato analizzato distinguendo i commenti in tre periodi di pubblicazione: meno di un

anno, tra i due e i quattro anni, e oltre i cinque anni fa.




Figura 47: Distribuzione del sentiment per periodo di pubblicazione in conteggi assoluti e in percentuali

L'analisi percentuale evidenzia alcune dinamiche interessanti. Nei commenti più recenti (meno di un anno), il sentiment positivo risulta relativamente più elevato rispetto agli altri periodi: passa infatti dal 29,5% al 35,1%. Nello stesso periodo, tuttavia, si osserva anche un aumento della componente negativa, che va dal 36,9% al 45,1%, a discapito di una netta riduzione dei commenti neutri. Nel complesso, nel tempo si assiste ad un aumento sia dei commenti positivi che di quelli negativi, mentre diminuiscono quelli neutri, ma tali variazioni non sembrano essere particolarmente importanti.

Al fine di verificare se le differenze osservate nella distribuzione del sentiment nei diversi periodi temporali fossero statisticamente significative, è stato applicato un test χ^2 di indipendenza tra il sentiment dei commenti e il periodo di pubblicazione. I risultati ($\chi^2 = 5.45$, $df = 4$, $p = 0.244$) indicano che non emergono differenze significative nella distribuzione del sentiment tra i diversi periodi temporali, come avevamo ipotizzato.

9.2.6 Clustering tramite spherical k-means

Per l'analisi del contenuto testuale dei commenti è stato applicato un *clustering* partizionale *spherical k-means*. A differenza del *k-means* tradizionale, che si basa sulla distanza euclidea, lo *spherical k-means* utilizza la similarità coseno. In questo modo, il raggruppamento dei documenti dipende esclusivamente dalla direzione dei vettori nello spazio delle caratteristiche (distribuzione relativa dei termini), ignorandone la norma, risultando particolarmente adatto a rappresentazioni testuali ad alta dimensionalità.

Dopo aver provato differenti valori di k (numero di cluster), lo si è scelto pari a 3, in quanto si è ritenuta più significativa l'interpretazione che ne deriva. Come si può osservare dalla figura 48, i cluster hanno dimensioni molto differenti.




Figura 48: Dimensioni dei tre cluster

In particolare, al cluster 3 sono stati assegnati la maggior parte dei documenti, mentre 1 e 2 sono più o meno bilanciati tra di loro.

Per trarre fuori informazioni da questa classificazione, si è costruita una *word-cloud* (Figura 49) che contiene per ogni gruppo le parole più rappresentative.




Figura 49: *Wordcloud* suddivisa nei tre *cluster*

I *cluster* 1 (in verde) e 2 (in arancione) condividono una forte componente polemica, ma si distinguono per il piano su cui tale polemica viene articolata.

Infatti, il *cluster 2* è caratterizzato da un lessico legato alla sfera scientifica e nutrizionale, con termini che richiamano figure professionali (come nutrizionista), concetti di competenza, studio e validità scientifica, e che suggeriscono una contestazione dei fondamenti nutrizionistici della dieta vegana, mettendone in discussione l'adeguatezza o la correttezza dal punto di vista medico-scientifico. Il *cluster 1*, invece, pur mantenendo un tono conflittuale, sposta invece il focus dal piano tecnico a quello identitario e relazionale, concentrandosi maggiormente sul vegano come persona, sulle sue scelte individuali e sul modo in cui queste vengono percepite e giudicate nel confronto pubblico.

Il *cluster 3* si differenzia nettamente dai precedenti, presentando un vocabolario maggiormente orientato a questioni etiche e valoriali, con riferimenti alla vita animale, alla moralità delle scelte alimentari e alle implicazioni etiche del consumo di prodotti di origine animale (allevamenti, uccidere, intensivi, etico, scelta). In questo caso, il discorso appare meno centrato sulla polemica diretta e più su una riflessione di principio, evidenziando come, accanto al conflitto e alla contestazione, il veganismo venga anche inquadrato come posizione etica e morale.

Nel complesso, il *clustering* tramite *spherical k-means* consente di mettere in luce non solo la presenza di un dibattito polarizzato, ma anche la coesistenza di registri argomentativi differenti — scientifico-nutrizionale, identitario-polemico ed etico — che strutturano il discorso online sul veganismo.

9.3 Analisi testuale degli articoli sul tema veganismo

In questa sezione viene analizzato un dataset di articoli in lingua inglese presente con il nome di "Vegan News" sulla piattaforma Kaggle. I dati provengono dalle pagine web "Plant Based News", "VegNews" e "Vegconomist" ed i temi trattati si legano più o meno direttamente al mondo dell'alimentazione vegana.

9.3.1 Studio e pulizia del dataset

La tabella conta 27651 unità suddivise per quattro colonne, rappresentanti titolo, link all'articolo sul web, data di pubblicazione e testo. In particolare, gli articoli sono stati pubblicati in un intervallo temporale che va dal 2002 fino all'anno 2021, con una maggiore attività concentrata negli ultimi anni, e, in

generale, crescente nel tempo. Per questo motivo, il dataset è stato suddiviso in tre macro-classi, secondo il periodo di pubblicazione dei singoli articoli:

- Periodo **Early**. Questo periodo - dal 2002 al 2010 - è caratterizzato da un numero di documenti minore, probabilmente a causa del minore utilizzo del web come strumento mediatico di informazione, e della ridotta popolarità del tema. Inoltre la distribuzione dei dati non è uniforme all'interno della stessa classe, ma, al contrario, è molto sbilanciata verso gli ultimi anni (dal 2002 al 2007 vi sono soltanto due articoli)
- Periodo **Growht**. In questo intervallo di tempo - fino al 2016 - assistiamo ad un iniziale aumento del numero di testi pubblicati.
- Periodo **Boom**. Quest'ultimo gruppo vede aumentare significativamente le pubblicazioni in merito al tema del veganismo, e copre il periodo che va dal 2017 al 2021. Pertanto, si tratta della classe più numerosa.

Di seguito il grafico della distribuzione degli articoli negli anni, e all'interno delle rispettive categorie.




Figura 50: Grafico a barre per la pubblicazione degli articoli del dataset

Come è possibile osservare, si è in presenza di un dataset molto sbilanciato, oltre che di notevoli dimensioni. A questo proposito, si è pensato di appianare le differenze quantitative tra le classi e allo stesso tempo di ridurre l'ammontare complessivo di dati a disposizione; nello specifico, il numero di elementi all'interno di ogni classe è stato fissato a 500, per un totale di 1500 documenti a disposizione e 331838 caratteri. È bene notare che tale operazione non inficia sulla qualità generale dell'analisi, dal momento che rimanere fedeli alle reali distribuzioni interne alle classi non è stato considerato di primaria importanza per

gli scopi dell'indagine; oltretutto, ridurre le dimensioni del dataset è condizione necessaria, tenuto conto dei mezzi di calcolo a disposizione.

9.3.2 Creazione del corpus e prime analisi

In seguito allo step iniziale di pulizia del dataset, è stato necessario costruire il corpus, in modo da predisporre i dati all'analisi testuale. Come da prassi, si è proceduto alla normalizzazione del testo contenuto in ciascun documento, mediante l'utilizzo della libreria `tm` messa a disposizione da R.

Al fine di determinare la stabilità del corpus, è stato calcolato il TTR (*Type/-Token Ratio*) e la percentuale di Hapax, ovvero i termini che occorrono una sola volta all'interno del testo. Il risultato evidenzia un valore del 14% circa per il TTR, mentre la percentuale di Hapax è pari al 48%. Entrambi risultano inferiori ai valori limite stabiliti in letteratura, sottolineando in questo modo quanto il corpus sia sotto il limite di rumorosità ammessa secondo questo criterio.

Successivamente, si è proceduto a creare la così detta tabella termini-documenti, la quale permette di considerare i termini in funzione dei documenti in cui compaiono e viceversa. Tra i diversi criteri disponibili per costruire la suddetta matrice, è stato ritenuto più funzionale il modello *bag-of-words* (BoW), dal momento che permette di contare le frequenze totali di ciascuna parola; a tal proposito, la figura 51 riporta il grafico a barre dei termini con maggiore occorrenza all'interno dei documenti.




Figura 51: Frequenze dei termini con maggiore occorrenza

I risultati osservati non si discostano dalle aspettative: confermano che il tema principale degli articoli è il discorso intorno al veganismo, un'abitudine alimen-

tare di cui si sta parlando con più attenzione negli ultimi anni e che è caratterizzata da emergenti spunti di dibattito, a livello nutrizionistico, industriale, etico e sociale, particolare che spiega la presenza preponderante della parola "nuovo". Il termine "plantbased" è strettamente legato alle recenti scoperte in ambito scientifico, che consentono di produrre surrogati di carne di origine totalmente vegetale, aprendo la strada a nuovi mercati. "Veganismo" è un concetto che, come ricordato in precedenza, non è possibile ridurre ad un mero stile alimentare, ma abbraccia tutto un ventaglio di questioni, tra tutte etica e società, e rappresenta un forte elemento di identificazione individuale e collettiva che, in quanto tale, può generare opposizioni e forti polemiche con coloro che non condividono gli stessi valori. Per questo motivo, anche il termine "persone" è presente con una certa intensità all'interno dei documenti.

Rimanendo nell'ambito del calcolo delle frequenze, la libreria `udpipe` di R permette di scaricare un modello di *Natural Language Processing* in grado di operare una lemmatizzazione sui termini del corpus, ovvero di ridurre ciascuna parola al proprio lemma di base, diminuendo così eventuali ripetizioni e quindi rumore. Quest'approccio è stato preferito allo *stemming* in quanto preserva una maggiore chiarezza nell'interpretabilità dei risultati. Di conseguenza, sono state ricalcolate le frequenze rispetto ai *token* generati dal modello, e distinguendo tra nomi e aggettivi, come è possibile osservare nella figura 52.




Figura 52: Frequenze di nomi e aggettivi calcolati con `udpipe`

Osservando il grafico dei nomi che occorrono maggiormente, emerge in modo più chiaro il tema dell'industria alimentare: quest'ultima deve far fronte a nuove e crescenti esigenze di consumo, le quali promettono nuove opportunità di guadagno alle aziende in grado di intercettarle, differenziando la produzione o allineandosi maggiormente ai discorsi di carattere etico sull'allevamento degli animali. Un ragionamento analogo è valido anche per il mondo della ristorazio-

ne, messo in risalto da parole come "ristorante" e "burger", in cui crescono le richieste di un menù *vegan-friendly* da parte dei clienti.

Inoltre, parole come "salute" e "mondo" rimandano al tema della sostenibilità; sia ambientale, legata al massiccio consumo di CO2 derivante dall'industria della carne; sia riguardante la capacità di una dieta che esclude la carne di garantire il giusto apporto di nutrienti necessari alla salute dell'individuo.

Nel grafico emergono anche i termini "cheese" e "milk". Il motivo deriva probabilmente dal dibattito sull'esclusione di questi alimenti dalla dieta: infatti, una delle differenze fondamentali tra vegetariani e vegani è che quest'ultimi non consumano prodotti che siano anche solo indirettamente di origine animale, come latte e formaggi.

Nel grafico degli aggettivi più ricorrenti è possibile notare come emerga con maggiore forza il tema dell'etica ambientale con termini come "salutare", "ambientale", "organico". Allo stesso tempo, tuttavia, termini come "disponibile", "aperto", "pubblico" possono evidenziare una criticità nella fruizione di alimenti a base di verdure da parte della popolazione meno abbiente: infatti, i prezzi di questi prodotti sono mediamente più alti, complice anche un mercato ancora non sufficientemente sviluppato, caratterizzato da costi più elevati per le aziende.

Un altro strumento di visualizzazione delle parole che più caratterizzano il testo è la *wordcloud*, o nuvola di parole, rappresentata di seguito.



Figura 53: Nuvola delle parole per il dataset "Vegan News"

La nuvola di parole non fa altro che rappresentare in modo più compatto e

diretto i termini visti in precedenza nei grafici a barre, ma allarga la lente anche ad ulteriori termini ricorrenti, posizionati più esternamente. La parola "crueltyfree", ad esempio, riflette uno degli argomenti principali proposti dalla causa vegana, ovvero scegliere di non consumare più carne, in quanto prodotto che deriva dall'uccisione e dalla sofferenza di altri esseri viventi. Anche il termine "alternative" si pone in continuità con questa linea argomentativa, indicando la scelta di consumare alimenti che non comportino violenza né l'uccisione di altri esseri viventi. Tale orientamento può tradursi, da un lato, in un maggiore consumo di verdure e di alimenti ad alto contenuto proteico di origine vegetale, come tofu o seitan, funzionali a compensare l'assenza delle proteine di origine animale; dall'altro, nell'adozione di prodotti *plantbased* come gli hamburger vegetali, concepiti come alternative dirette ai prodotti tradizionalmente a base di carne.

9.3.3 Algoritmo RAKE e Analisi delle Concordanze

In questa fase dell'analisi, di carattere puramente esplorativo, viene utilizzato l'algoritmo RAKE per studiare le parole maggiormente associate nel testo, l'analisi delle concordanze per esaminare dei *token* candidati all'interno del proprio contesto.

L'algoritmo RAKE ordina coppie di parole secondo uno *score* calcolato a partire dal grado e dalla frequenza delle stesse. La figura 54 mostra le coppie con il maggiore grado di associazione secondo il suddetto criterio.




Figura 54: Algoritmo RAKE per il dataset "Vegan News"

La classificazione operata dall'algoritmo mostra le associazioni più rilevanti individuate nel testo. In prima posizione si trova "foie gras", un piatto tradizionale francese a base di fegato animale, probabilmente oggetto di aspra critica dalla

comunità vegana. In generale, si fa riferimento ai temi principali già discussi precedentemente, come il mercato dei prodotti a base vegetale come alternativa alla carne, i timori rispetto al cambiamento climatico e la sostenibilità delle abitudini alimentari mondiali, i diritti e la salute degli animali e il discorso sul latte e i suoi derivati. Emerge, inoltre, l'argomento riguardante lo spreco di cibo, e si cita Burger King, uno dei colossi del fast food di stampo americano presente in tutto il mondo, famoso per i suoi hamburger di carne, e probabilmente inserito in un discorso polemico o legato all'introduzione di panini vegani nel menù.

Attraverso l'analisi delle concordanze è possibile approfondire il contesto semantico di una parola chiave. Per via della normalizzazione, le concordanze non restituiscono frasi grammaticalmente complete; ciò che si osserva non è una frase ma una finestra di co-occorrenza lessicale, utile a ricostruire i pattern discorsivi entro cui un determinato termine viene impiegato. L'interpretazione si basa sull'integrazione semantica dei frammenti contestuali, che consente di individuare i principali frame discorsivi associati al termine, indipendentemente dalla ricostruzione sintattica originaria.

In continuità con l'applicazione dell'algoritmo RAKE, l'analisi delle concordanze è stata effettuata sulle associazioni evidenziate dall'algoritmo. Nel corpus analizzato, il termine «foie gras» ricorre in contesti lessicali caratterizzati dalla co-occorrenza di espressioni riferite a pratiche zootecniche invasive, impatti ambientali, conflitti con le comunità locali e interventi normativi. Alcuni esempi prodotti dall'analisi sono: "taildocking dairy cows forcefeeding ducks foie gras conventional poultry slaughter methods", o "harming animals environment local residents foie gras french delicacy perennially controversial dish". Il primo risultato mostra il termine "foie gras" in un contesto che lo accosta ad altre pratiche zootecniche invasive, quali il *tail docking* nelle vacche da latte e il *force-feeding* delle anatre, inserendolo all'interno di una rappresentazione sistemica dell'allevamento intensivo e delle pratiche di macellazione convenzionali. Nel secondo esempio, invece, è possibile notare come in altri contesti, il foie gras è associato ad un lessico di danno che coinvolge animali, ambiente e comunità locali - le *factory farms* di foie gras sono spesso associate all'inquinamento delle acque, contaminazione del suolo, cattivi odori persistenti e aumento di insetti e parassiti. Al contempo viene qualificato come una "french delicacy" e come un piatto perennemente controverso, evidenziando la tensione tra valore culturale e critica etico-sociale. Pertanto, sebbene le concordanze non restituiscano frasi sintatticamente complete, l'insieme dei frammenti consente di ricostruire un

frame discorsivo coerente.

Volendo analizzare il contesto semantico del termine "global market", quest'ultimo ricorre in contesti caratterizzati da un registro tecnico-economico, in cui il veganismo è descritto come un fenomeno in crescita, oggetto di analisi da parte di società di ricerca e associato a processi di innovazione, trasformazione dei consumi e sviluppo di nuovi prodotti. In questo frame, il veganismo è costruito prevalentemente come opportunità di mercato e come tendenza del lifestyle contemporaneo, piuttosto che come scelta etica o politica. Si prendano in esempio i seguenti risultati: "research technavio veganism gaining traction global market style living philosophy people increasingly", e "story innovations vegan leather means global market hit billion luxury fashion retailer". La prima sequenza associa il veganismo a un discorso di tipo analitico ed economico, in cui il fenomeno è descritto come in crescita nel mercato globale e progressivamente ridefinito come stile di vita e filosofia di consumo; mentre nella seconda unità discorsiva, il veganismo è rappresentato come motore di innovazione di prodotto, capace di affermarsi anche nel settore della moda di lusso, dove alternative come la "vegan leather" sono associate a risultati economici di grande rilevanza. Infine, se si esaminano le concordanze del termine "animal rights" emerge un discorso fortemente orientato all'azione collettiva e all'attivismo politico: "animalrights group israel marked international animal rights day tel aviv protesting factory", "bend ankle mills whose campaigning animal rights environmental issues human rights helped". In un caso l'unità associa i diritti animali a forme di attivismo collettivo e pubblico, collocate in uno spazio urbano specifico e legate a momenti simbolici di mobilitazione internazionale, in cui la protesta si indirizza esplicitamente contro strutture produttive. Nell'altro, i diritti animali sono inseriti in un discorso più ampio di intersezione tra cause, in cui l'attivismo animalista è rappresentato come contributo positivo anche alla tutela ambientale e ai diritti umani.

9.3.4 Analisi comparativa secondo il periodo di pubblicazione

Questa sezione dell'analisi si propone di studiare il dataset secondo l'organizzazione in periodi già menzionata in precedenza, con lo scopo di evidenziare eventuali differenze caratterizzanti ciascun gruppo. I dati sono stati ordinati in base al periodo di pubblicazione, ovvero **Early**, **Growth**, **Boom**. Ciascun gruppo presenta 500 osservazioni, per un totale di 1500 documenti.

Una prima indagine esplorativa è stata effettuata attraverso la *Comparison Cloud* (figura 55), uno strumento che consente di visualizzare le parole che occorrono maggiormente in ciascun insieme, secondo la frequenza relativa delle parole. In generale, per ciascun gruppo mostra le parole più frequenti, in proporzione, rispetto agli altri gruppi.




Figura 55: *Comparison Cloud* per il dataset "Vegan News"

La *Comparison Cloud* evidenzia una chiara evoluzione diacronica del discorso sul veganismo nei diversi periodi di pubblicazione. Nella fase **Early**, il lessico dominante è associato a una dimensione personale e informale, vicina al vegetarianismo e ai valori della naturalità e dello stile di vita green, con una forte presenza di termini legati alla comunicazione individuale e quotidiana. Il periodo **Growth** è caratterizzato da una minore densità lessicale. Si rilevano soltanto tre termini con una frequenza relativa sostanzialmente maggiore, ad ogni modo non sufficienti a distinguere il periodo dal punto di vista del lessico. Nel periodo **Boom**, infine, il discorso è nettamente dominato da termini orientati al mercato e ai prodotti, con la centralità della parola “plantbased” e numerosi riferimenti a brand, lancio di nuovi prodotti e dinamiche di domanda e offerta. In questa fase, il veganismo risulta pienamente integrato nel discorso mainstream del consumo e dell’industria alimentare.

A partire da questa prima analisi esplorativa, basata sulla distribuzione delle frequenze relative nei diversi periodi, si è ritenuto opportuno approfondire ulteriormente la struttura del corpus attraverso l’impiego di IRaMuTeQ. Tale strumento consente di affiancare all’analisi quantitativa delle frequenze un

approccio lessico-statistico più articolato, volto a individuare le associazioni tra forme linguistiche e gruppi di testi, nonché a mettere in luce le specificità lessicali che caratterizzano ciascun periodo.

L'analisi condotta con IRaMuTeQ permette dunque di superare una lettura puramente basata sulla salienza delle parole, concentrandosi invece sulla distribuzione differenziale del lessico all'interno del corpus e sulle configurazioni discorsive emergenti nei diversi sottogruppi temporali. In questo modo, è possibile osservare non solo quali termini siano più frequenti, ma soprattutto quali forme risultino statisticamente caratteristiche di ciascun periodo, contribuendo a una comprensione più approfondita dell'evoluzione del discorso sul veganesimo. Pertanto, i risultati che seguono sono stati ottenuti attraverso l'utilizzo del suddetto software.

Come è possibile osservare dalla figura 56, relativa alle dimensioni dei segmenti testuali, la distribuzione della loro lunghezza mostra un andamento unimodale e relativamente concentrato, suggerendo una segmentazione equilibrata del corpus. La maggior parte dei segmenti presenta una dimensione intermedia, condizione favorevole per le successive analisi lessico-statistiche, in quanto limita la presenza di unità eccessivamente brevi o sproporzionatamente lunghe.




Figura 56: Distribuzione della lunghezza dei segmenti testuali

La curva di Zipf (figura 57) evidenzia una distribuzione lessicale coerente con le leggi statistiche del linguaggio naturale, caratterizzata dalla presenza di un

numero limitato di forme ad alta frequenza e da una lunga coda di forme rare. Tale andamento conferma la qualità e la naturalezza del corpus analizzato.




Figura 57: Curva di Zipf

Successivamente è stata eseguita con IRaMuTeQ l'analisi fattoriale delle corrispondenze (AFC): La mappa fattoriale delle forme lessicali (figura 58) rappresenta una visualizzazione sintetica delle relazioni tra le parole del corpus, ottenuta mediante la suddetta analisi. Le forme che occupano posizioni centrali nella mappa corrispondono a un lessico ampiamente condiviso, mentre quelle situate ai margini risultano maggiormente discriminanti e contribuiscono alla differenziazione tra gruppi di testi.




Figura 58: Mappa fattoriale delle forme lessicali e dei periodi del dataset

La mappa fattoriale delle forme mostra una forte concentrazione del lessico attorno a un nucleo centrale condiviso, indicando una notevole omogeneità tematica del corpus. Le forme più distanti dal centro risultano invece maggiormente discriminanti e contribuiscono alla differenziazione tra i periodi.

La proiezione dei periodi nella mappa fattoriale evidenzia una chiara separazione tra le tre fasi temporali considerate. Tale disposizione indica che i periodi Early, Growth e Boom presentano profili lessicali distinti, confermando la rilevanza della suddivisione cronologica adottata.

Le percentuali associate alle dimensioni fattoriali indicano la quota di inerzia spiegata da ciascun asse. Le prime dimensioni concentrano la parte più rilevante dell'informazione e consentono di interpretare i principali contrasti lessicali all'interno del corpus. Sebbene la concentrazione di una quota rilevante di inerzia nelle prime dimensioni possa apparire elevata, tale risultato è coerente con la natura del corpus analizzato. Trattandosi di testi che condividono un medesimo ambito tematico, le principali differenze lessicali tra i periodi risultano strutturate lungo pochi assi dominanti, riconducibili a trasformazioni discorsive sistematiche piuttosto che a variazioni casuali.

L'analisi delle specificità lessicali consente di individuare le forme che caratterizzano in modo significativo ciascun gruppo testuale rispetto all'insieme del corpus. A differenza delle analisi basate sulla sola frequenza assoluta, questo approccio mette in evidenza le parole che risultano sovra- o sotto-rappresentate in un determinato sottoinsieme, tenendo conto della distribuzione globale delle

forme. In tal modo, l'analisi delle specificità permette di descrivere con maggiore precisione i tratti distintivi del discorso associato a ciascun periodo di pubblicazione, evidenziando le scelte lessicali che contribuiscono a differenziare le fasi "Early", "Growth" e "Boom".

Le forme lessicali più specifiche del periodo **Early** delineano un discorso fortemente ancorato alla dimensione quotidiana e individuale del veganismo. Il lessico caratterizzante rimanda, da un lato, alle pratiche alimentari domestiche e agli ingredienti, come nel caso di termini quali "recipe", "kitchen" e "spinach"; dall'altro, emerge una sensibilità etica incentrata sul benessere animale e sulla protezione degli animali, espressa attraverso forme quali "animal", "welfare", "sanctuary" e "rescue". L'assenza di termini riconducibili alla sfera del mercato e dell'industria alimentare suggerisce che, in questa fase iniziale, il veganismo venga prevalentemente rappresentato come una scelta personale e morale, piuttosto che come un fenomeno economico strutturato.

Il periodo **Growth** si configura come una fase di transizione discorsiva, in cui il veganismo viene progressivamente sottratto alla dimensione esclusivamente personale per essere riformulato all'interno di un quadro più ampio, che combina istanze etiche, ambientali e prime logiche di visibilità pubblica. Le forme lessicali specifiche di questo periodo non delineano un campo semantico nettamente autonomo, quanto piuttosto un discorso ibrido, sospeso tra sensibilità individuale e apertura verso una sfera più collettiva e mediatizzata. Da un lato, permangono riferimenti riconducibili all'universo etico e ambientale, come "cruelty", "animal", "recycle", "carbon", "emission" ed "eco", che indicano la continuità di un discorso morale incentrato sulle conseguenze ambientali e sul benessere animale. Dall'altro lato, iniziano a comparire elementi legati alla circolazione pubblica del tema, attraverso termini quali "television", "website", "festival", "giveaway" e "social media", che suggeriscono una crescente esposizione mediatica del veganismo.

Accanto a questi aspetti, il lessico del periodo "Growth" mostra una maggiore attenzione alla dimensione dell'esperienza e della scoperta, con forme come "examine", "consider", "study" e "reveal", che rimandano a un processo di valutazione e legittimazione progressiva del veganismo, più che a una sua piena normalizzazione. In questo senso, il periodo "Growth" appare come una fase di assestamento discorsivo, in cui il veganismo viene progressivamente reso visibile, discutibile e condivisibile, senza essere ancora pienamente integrato nel

linguaggio strutturato del mercato e dell'industria.

Nel periodo **Boom** emerge con forza un discorso nettamente orientato alla dimensione economica, industriale e commerciale del veganismo. Il lessico caratterizzante è dominato da termini riconducibili al mercato e alla produzione, quali "market", "product", "brand", "launch", "company" e "supermarket", che segnalano l'integrazione del veganismo all'interno delle dinamiche del consumo e della distribuzione su larga scala. Accanto a questi, emergono numerosi riferimenti a categorie merceologiche e prodotti specifici, come "burger", "sausage", "dairy", "milk" e "plantbased", a indicare una crescente standardizzazione dell'offerta e una forte attenzione alla varietà commerciale.

Questo periodo è inoltre caratterizzato da un lessico legato all'innovazione e agli investimenti, con la presenza di forme quali "innovation", "startup", "investment", "investor" e "technology", che riflettono una rappresentazione del veganismo come settore in espansione e ambito di interesse economico. La ricorrenza di termini temporali e contestuali come 2019, 2020, 2021 e il termine "pandemic" suggerisce infine un discorso fortemente ancorato all'attualità e alle trasformazioni recenti del mercato globale. Nel complesso, il veganismo nel periodo "Boom" appare pienamente inserito nel linguaggio mainstream dell'industria alimentare, configurandosi non più come pratica di nicchia, ma come fenomeno strutturato e commercialmente rilevante.

9.3.5 Analisi delle corrispondenze fattoriali e Clustering sul corpus

A differenza dell'AFC precedente, costruita a partire dalla variabile temporale dei periodi di pubblicazione, la presente analisi fattoriale delle corrispondenze si basa sulle classi lessicali emerse dalla classificazione discendente gerarchica. Essa consente di individuare le principali strutture tematiche del corpus, mettendo in luce i diversi universi discorsivi che organizzano il lessico, indipendentemente dalla loro distribuzione cronologica.

Dal punto di vista metodologico, la classificazione discendente gerarchica può essere ricondotta al paradigma dei clustering gerarchici divisivi: il corpus viene inizialmente considerato come un unico insieme e successivamente suddiviso in classi attraverso partizioni successive, guidate da criteri di dissimilarità lessicale. A differenza dei tradizionali algoritmi di clustering, tuttavia, questo metodo opera su segmenti testuali e utilizza opposizioni statisticamente significative tra forme lessicali come principio di suddivisione. La figura 59 mostra la distribuzione delle parole all'interno dello spazio fattoriale.




Figura 59: AFC delle classi lessicali del corpus: distribuzione delle forme nello spazio fattoriale

Le prime due dimensioni, rappresentate sul piano, spiegano circa il 52% dell'inerzia totale. Questo dato sottolinea che esistono ulteriori dimensioni rilevanti, necessarie a rappresentare più accuratamente i termini sul piano. Di seguito la tabella dei fattori:

Fattore	Percentuale (%)	Percentuale cumulata (%)
Fattore 1	30.43	30.43
Fattore 2	21.64	52.06
Fattore 3	18.31	70.38
Fattore 4	17.56	87.94
Fattore 5	12.06	100.00

Tabella 6: Percentuali di inerzia spiegata dai fattori dell'AFC

Analogamente, il dendrogramma nella figura 60 rappresenta il risultato della classificazione discendente gerarchica applicata al corpus, che suddivide i segmenti testuali in sei classi lessicalmente omogenee. Il processo di classificazione mostra una buona qualità complessiva, come indicato dall'elevata percentuale di segmenti classificati (oltre il 97%).




Figura 60: Dendrogramma della classificazione del corpus.

Il dendrogramma consente di collegare ciascun ramo a specifici universi lessicali. La classificazione individua sei classi, caratterizzate da una distribuzione quantitativamente equilibrata.

La prima grande biforcazione separa due macro-aree del discorso. Nel ramo sinistro si colloca la **classe 1** (15,7%), che possiede una tematizzazione più legata alla dimensione alimentare strettamente intesa. In particolare, è dominata da un lessico culinario e sensoriale, con termini come "flavor", "chocolate", "cream", "salad", "coconut", "dessert", che rimandano a una rappresentazione del veganismo attraverso ricette, ingredienti e gusto.

Nel ramo centrale del dendrogramma si collocano la classe 5 e la classe 2, che mostrano, di conseguenza, una maggiore prossimità lessicale pur mantenendo una chiara distinzione semantica.

La **classe 2** (13,2%), è caratterizzata da un vocabolario giuridico e istituzionale ("animal", "law", "farm", "ban", "legislation", "investigation", "abuse", "welfare"), indicando un discorso centrato sulla tutela animale, sulle normative e sulle pratiche di controllo e denuncia.

D'altro canto, la **classe 5** (22,3%) è rappresentata da un lessico legato alla dimensione pubblica e mediatica del veganismo ("event", "host", "celebrity", "award", "Los Angeles", "social", "activist", "vegan"), riconducibile a eventi, personaggi noti, attivismo e visibilità sociale. La vicinanza strutturale tra le due classi suggerisce un passaggio dal veganismo come fenomeno di esposizione pubblica e mobilitazione simbolica a una sua traduzione in ambito giuridico e istituzionale.

Il ramo destro del dendrogramma raggruppa le classi 3, 4 e 6, che risultano tra loro più vicine dal punto di vista lessicale e tematico. La **classe 3** (10,8%) è fortemente caratterizzata da un discorso ambientale e scientifico, con termini come "emission", "gas", "carbon", "climate", "pollution", "waste", che inscrivono il veganismo all'interno del dibattito su sostenibilità, cambiamento climatico e impatti ecologici.

La **classe 4** (14,5%) si concentra invece sugli aspetti legati alla salute e alla dieta, con parole quali "diet", "health", "weight", "nutrition", "disease", "cholesterol", configurando il veganismo come pratica alimentare orientata al benessere individuale e alla prevenzione.

Infine, la **classe 6** (23,5%), la più ampia, è dominata da un lessico economico e di mercato ("product", "company", "market", "brand", "consumer", "supermarket"), che restituisce un'immagine del veganismo pienamente integrata nelle logiche dell'industria alimentare e del consumo di massa.

9.3.6 Latent Dirichlet Allocation per il topic modeling

Dopo aver analizzato il corpus attraverso strumenti di tipo lessicometrico e fattoriale, finalizzati a mettere in luce le principali strutture discorsive e le opposizioni semantiche che organizzano il lessico, questa sezione introduce un ulteriore livello di analisi basato sul topic modeling, e in particolare sul modello di Latent Dirichlet Allocation (LDA).

Mentre le analisi precedenti hanno consentito di individuare classi lessicali coerenti e di rappresentarne le relazioni reciproche nello spazio fattoriale, il topic modeling permette di affrontare il corpus da una prospettiva complementare, orientata all'individuazione di temi latenti che attraversano i testi in modo trasversale. LDA assume infatti che ciascun documento sia una combinazione probabilistica di più topic, e che ogni topic sia definito da una distribuzione di parole caratteristiche, consentendo così di cogliere la compresenza e l'intreccio di diversi registri tematici all'interno dei singoli articoli.

Pertanto, l'analisi di topic modeling mira ad integrare le precedenti analisi lessicali e fattoriali, consentendo di individuare i principali nuclei tematici latenti del corpus, la loro coesistenza nei documenti e la loro distribuzione nei diversi periodi di pubblicazione.

Il modello LDA è stato stimato mediante campionamento di Gibbs, come implementato nel pacchetto `topicmodels` di R. Il *Gibbs sampling* è un algoritmo di inferenza bayesiana approssimata che consente di stimare le distribuzioni latenti

dei topic iterando un processo di campionamento condizionato sulle assegnazioni parola-topic. Tale approccio risulta particolarmente adatto a corpora testuali di dimensioni medio-grandi e caratterizzati da elevata eterogeneità lessicale, come quello in esame, poiché permette di esplorare in modo flessibile la struttura latente del discorso senza imporre vincoli rigidi sulla forma dei topic.

In una prima fase, il modello LDA è stato stimato impostando un numero di topic pari a $k = 6$, in coerenza con le sei classi individuate attraverso la Classificazione Gerarchica Discendente. Tale configurazione ha permesso di individuare alcuni nuclei tematici chiari, riconducibili rispettivamente al discorso animalista, al consumo e allo stile di vita vegano, alla dimensione nutrizionale e sanitaria, nonché al mercato dei prodotti plant-based.




Figura 61: Distribuzione delle top 10 parole all'interno dei topic con $k = 6$

Come dimostra la figura 61, l'analisi delle parole a maggiore probabilità associate a ciascun topic ha evidenziato una forte eterogeneità interna ad alcuni di essi. In particolare, temi distinti come mercato, industria, innovazione e branding risultavano frequentemente accorpati all'interno dello stesso topic, così come aspetti legati alla salute, alla dieta e alla ricerca scientifica. Inoltre, la presenza di topic caratterizzati prevalentemente da termini ad alta frequenza e basso contenuto semantico suggeriva una eccessiva compressione della struttura tematica del corpus.

Per tali ragioni, si è ritenuto opportuno aumentare il numero di topic, adottando una configurazione più articolata ($k = 15$), al fine di ottenere una rappresentazione più fine e interpretabile delle diverse dimensioni discorsive presenti nel corpus.




Figura 62: Distribuzione delle top 10 parole all'interno dei topic con $k = 15$

L'analisi di topic modeling con $k = 15$ restituisce una mappa tematica articolata, nella quale il discorso sul veganismo si distribuisce lungo più assi semantici distinti ma interconnessi. I topic individuati mostrano un buon livello di coerenza interna e permettono di distinguere con maggiore finezza le diverse modalità attraverso cui il veganismo viene rappresentato nel corpus.

Alcuni topic risultano chiaramente riconducibili alla dimensione alimentare e gastronomica. In particolare, il **topic 4** si concentra su ingredienti e preparazioni dolciarie, come “chocolate”, “tofu”, “coconut” e “ingredients”, suggerendo un discorso fortemente legato alla cucina vegana e alla sperimentazione gastronomica. In modo complementare, il **topic 2** richiama il contesto della ristorazione e dell'offerta commerciale, con termini quali “burger”, “cheese”, “menu” e “restaurant”, evidenziando la normalizzazione del veganismo all'interno delle pratiche di consumo fuori casa.

Un secondo insieme di topic mette in luce il veganismo come fenomeno economico e di mercato. Il **topic 1** e il **topic 12**, caratterizzati da parole come “products”, “companies”, “market”, “brand” e “plant-based”, costruiscono una rappresentazione del veganismo come settore industriale in espansione, inserito nelle logiche del business e dell'innovazione alimentare. Questi topic segnalano chiaramente lo spostamento del discorso dal piano della scelta individuale a quello della produzione e della distribuzione su larga scala.

Accanto a queste dimensioni emergono topic fortemente connotati sul piano

etico e animalista. Il **topic 3** e il **topic 5** richiamano il lessico della tutela animale e delle pratiche industriali, attraverso termini come “animals”, “farm”, “sanctuary”, “welfare”, “factory” e “abuse”. In questi casi il veganismo viene costruito come risposta morale a un sistema produttivo percepito come violento o ingiusto, rafforzando la dimensione politico-etica del discorso.

Un ulteriore asse tematico riguarda la salute e la nutrizione. Il **topic 7** è esplicitamente centrato su questo ambito, con parole quali “health”, “diet”, “study”, “research” e “vegetables”, che rimandano a un registro scientifico e informativo. Qui il veganismo è presentato come oggetto di valutazione medica e nutrizionale, spesso attraverso dati, studi e raccomandazioni.

La dimensione ambientale trova una formulazione chiara nel **topic 9**, caratterizzato da termini come “environment”, “agriculture”, “water” e “species”. In questo caso il veganismo viene inserito all’interno di un discorso più ampio sulla sostenibilità ecologica e sull’impatto dei sistemi alimentari sugli ecosistemi, rafforzando il legame tra scelta alimentare e crisi ambientale.

Altri topic contribuiscono a delineare il ruolo delle rappresentazioni culturali e mediatiche. Il **topic 11**, con riferimenti a luoghi ed eventi (“city”, “event”, “Los Angeles”), e il **topic 13**, che richiama il linguaggio dei media (“show”, “news”, “world”), mostrano come il veganismo sia anche un oggetto di narrazione pubblica e di visibilità simbolica. In modo più soggettivo, il **topic 10** sembra invece legato all’esperienza individuale e autobiografica, attraverso termini come “people”, “years”, “eating” e “veganism”.

Sebbene alcuni topic risultino riconducibili a uno stesso campo tematico generale, essi si differenziano per il registro discorsivo e per la funzione semantica svolta. LDA tende infatti a scomporre le aree tematiche più dense in sottotemi lessicalmente distinti, riflettendo la pluralità di prospettive attraverso cui il veganismo viene rappresentato nel corpus.

Ad esempio, i topic 1 e 12 risultano riconducibili a un medesimo ambito tematico generale, ovvero la dimensione economica e commerciale del veganismo, ma se ne distinguono chiaramente per l’angolazione discorsiva. Il topic 1 è infatti caratterizzato da un lessico che rimanda prevalentemente alla sfera della produzione e dell’offerta, con termini come “products”, “companies”, “business”, che costruiscono il veganismo come un vero e proprio settore produttivo inserito nelle logiche industriali e imprenditoriali. In questo caso, il discorso si

concentra sulle aziende, sui prodotti e sulle strategie di sviluppo, presentando il plant-based come ambito di innovazione e di investimento economico.

Il topic 12, pur muovendosi nello stesso campo semantico, si colloca invece sul versante opposto della filiera, privilegiando la dimensione del consumo e della domanda. La presenza di parole come "market", "consumers", "supermarket" orienta il discorso verso il comportamento dei consumatori, la distribuzione e il posizionamento dei prodotti sul mercato. Il veganismo viene così rappresentato non tanto come settore produttivo in sé, quanto come fenomeno di consumo, legato alle scelte individuali, al retail e alle dinamiche della domanda.

In questo senso, i due topic non riflettono una duplicazione tematica, ma piuttosto una scomposizione interna dello stesso macro-tema, che viene articolato in sottodimensioni coerenti: da un lato una prospettiva *producer-driven*, centrata sull'offerta e sulle imprese, dall'altro una prospettiva *consumer-driven*, focalizzata sul mercato e sui comportamenti di consumo. Questa distinzione evidenzia la capacità del modello di cogliere la complessità del discorso economico sul veganismo, restituendone le diverse funzioni e punti di vista.

Per riassumere, nel loro insieme, questi topic confermano che il discorso mediatico sul veganismo non si articola attorno a un unico nucleo tematico, ma si configura come un campo discorsivo complesso e stratificato, nel quale convivono pratiche quotidiane, istanze etiche, logiche di mercato, preoccupazioni ambientali e costruzioni mediatiche. L'aumento del numero di topic consente così di cogliere sfumature che, con una scomposizione più grossolana, rischierebbero di essere assorbite in categorie troppo ampie, offrendo una lettura più fine e aderente alla ricchezza semantica del corpus.

In continuità con l'analisi comparativa del precedente capitolo, i risultati del modello LDA vengono qui discussi spostando il focus sulle particolari distribuzioni dei topic all'interno di ciascun periodo di pubblicazione.




Figura 63: Distribuzione dei topic lungo ciascun periodo temporale

Topic	Early	Growth	Boom
T1	5.31	5.71	8.98
T2	5.77	7.24	7.88
T3	6.37	6.29	5.27
T4	6.71	7.15	5.81
T5	7.84	8.34	5.58
T6	8.68	6.29	6.44
T7	7.63	8.14	5.74
T8	6.79	5.94	5.85
T9	7.09	6.74	5.74
T10	6.50	6.18	6.44
T11	7.75	7.21	4.32
T12	5.22	6.29	11.17
T13	7.06	6.52	5.56
T14	5.22	5.95	7.74
T15	6.08	6.01	7.48

Tabella 7: Distribuzione percentuale dei topic LDA nei tre periodi temporali (Early, Growth, Boom).

Nel periodo **Early**, la distribuzione dei topic appare relativamente equilibrata, con valori che oscillano per la maggior parte tra il 5% e l'8%, segnale di un discorso ancora plurale e non fortemente polarizzato. Tuttavia, emergono già alcuni nuclei leggermente più probabili: in particolare il topic 6 (circa 8.7%) e il topic 5 (circa 7.8%) risultano tra i più presenti. Questi topic, legati rispettivamente a un registro discorsivo più conversazionale e a tematiche di tipo

etico-istituzionale (animali, welfare, stati, legislazione), suggeriscono che nella fase iniziale il veganismo venga discusso sia come questione morale e politica, sia come tema ancora fortemente inserito in narrazioni individuali e quotidiane. Accanto a questi, topic come il 7 (salute e dieta) e l'11 (contesti urbani, eventi, ristorazione) mantengono percentuali simili, indicando una coesistenza di argomentazioni salutistiche e culturali senza una netta gerarchia.

Nel periodo **Growth** si osserva una prima riorganizzazione delle probabilità tematiche. Alcuni topic mantengono una presenza stabile, ma altri iniziano a rafforzarsi in modo più chiaro. In particolare, il topic 5 cresce ulteriormente (oltre l'8%), mentre il topic 7 (salute, dieta, ricerca scientifica) e il topic 10 e 11, legati alla dimensione sociale e culturale urbana, restano ben rappresentati. Questa configurazione suggerisce che, nella fase di crescita, il discorso sul veganismo si strutturi maggiormente attorno a argomentazioni razionali e legittimanti (salute, studi, benefici), accompagnate da una crescente visibilità pubblica del fenomeno. Al contrario, i topic più legati alla scoperta iniziale o alla sperimentazione alimentare - come il topic 4, 6, 10 e 13 - rimangono presenti ma senza incrementi significativi, segno di una progressiva normalizzazione.

Il periodo **Boom** mostra invece una redistribuzione più marcata. Qui emerge con forza il topic 1 (circa 9%), insieme al topic 12 (oltre l'11%), entrambi riconducibili alla dimensione economica e di mercato: prodotti plant-based, aziende, consumatori, brand, lancio di nuovi prodotti. Parallelamente, alcuni topic legati alla fase discorsiva iniziale o alla dimensione più narrativa perdono peso relativo come il topic 4, 6 e 13. Anche il topic 14, associato a latte, dairy e alternative plant-based, cresce in modo significativo, indicando una focalizzazione sempre più esplicita sul confronto industriale tra filiere alimentari. In questa fase, il veganismo appare dunque prevalentemente rappresentato come settore economico maturo, inserito nelle logiche del mercato, dell'innovazione e della sostenibilità.

Nel complesso, l'analisi delle percentuali mostra che il passaggio da Early a Boom non implica l'eliminazione di specifici temi, ma una variazione nella loro probabilità relativa. I topic etici e salutistici risultano centrali nelle fasi iniziali e intermedie, mentre nel periodo Boom assumono maggiore rilevanza i topic economico-produttivi e quelli legati alla scala industriale e ambientale. Questo andamento conferma l'evoluzione del veganismo da pratica discorsivamente giustificata e pluralistica a campo tematico strutturato, dominato da pochi assi centrali e riconoscibili, coerentemente con quanto emerso dalle analisi CHD e

AFC.

9.3.7 Analisi del *sentiment*

Dopo aver analizzato la struttura tematica del corpus attraverso tecniche di classificazione e topic modeling, il lavoro si concentra ora sulla dimensione valutativa ed emotiva del discorso. Se le analisi precedenti hanno permesso di individuare di cosa si parla e come i contenuti si organizzano in temi ricorrenti, l'analisi del sentiment consente di approfondire con quale tonalità emotiva tali temi vengono trattati nel tempo.

A tal fine, è stata adottata una metodologia di sentiment analysis lessicale, basata sul modello delle emozioni di Plutchik, implementato attraverso il dizionario NRC (*National Research Council*). Il modello di Plutchik descrive le emozioni umane come un sistema articolato in otto emozioni fondamentali (*anger, anticipation, disgust, fear, joy, sadness, surprise, trust*), concepite come dimensioni primarie che possono combinarsi e variare in intensità.

L'approccio adottato è di tipo *dictionary-based*: le parole del corpus vengono confrontate con un lessico predefinito che associa ciascun termine a una o più categorie emotive. In questo senso, l'analisi non mira a classificare il sentiment dei singoli documenti, bensì a ricostruire la distribuzione complessiva delle emozioni che caratterizzano il discorso sul fenomeno analizzato. Il risultato è quindi una misura aggregata dell'intensità relativa delle diverse emozioni all'interno del corpus.

Un ulteriore obiettivo centrale di questo capitolo è il confronto diacronico del sentiment nei tre periodi individuati (*Early, Growth e Boom*). Attraverso il confronto delle distribuzioni emotive nei diversi intervalli temporali, l'analisi mira a verificare se e in che modo l'evoluzione tematica osservata nei capitoli precedenti si accompagni a una trasformazione del registro emotivo del discorso. In particolare, l'attenzione è rivolta all'emergere o al rafforzarsi di specifiche emozioni in relazione alla maturazione del dibattito, alla crescente istituzionalizzazione del tema e al suo ampliamento verso dimensioni economiche, politiche e sociali.




Figura 64: Analisi del sentiment secondo il modello di Plutchik

La distribuzione delle emozioni estratte dal corpus - rappresentata in figura 64 evidenzia un profilo emotivo complesso e non polarizzato, coerente con la natura informativa e argomentativa dei testi analizzati. Tra le otto emozioni considerate, **trust** emerge come la componente nettamente più rilevante in termini di frequenza. Questo risultato suggerisce che il discorso complessivo tende a costruire un frame di affidabilità, legittimazione e normalizzazione del tema trattato, spesso associato a lessico informativo, istituzionale o orientato alla credibilità scientifica ed economica. Inoltre, si tratta di un risultato prevedibile, data la natura delle fonti da cui sono stati ottenuti gli articoli, dichiaratamente favorevoli al tema.

Accanto a *trust*, si osserva una presenza marcata di **anticipation**, che rappresenta la seconda emozione più frequente. Tale dato può essere interpretato come un indicatore di un discorso proiettato verso il futuro, caratterizzato da aspettative, prospettive di sviluppo e narrazioni di cambiamento. In questo senso, l'*anticipation* appare coerente con la ricorrenza di temi legati all'innovazione, all'evoluzione del mercato e alle trasformazioni sociali individuate nelle analisi tematiche precedenti.

Un ruolo significativo è occupato anche da **joy**, che si colloca tra le emozioni più rappresentate. La sua presenza suggerisce che una parte rilevante del corpus adotta un registro positivo, spesso associato a benefici, scelte individuali, benessere e valori pro-sociali. Questa componente emotiva contribuisce a rafforzare l'immagine del fenomeno come esperienza desiderabile o migliorativa, più che

come semplice oggetto di dibattito controverso.

Le emozioni di **fear** e **sadness** risultano presenti ma con intensità più contenute. La *fear* può essere messa in relazione a temi critici come i rischi ambientali, sanitari o etici, mentre la *sadness* potrebbe riflettere un lessico legato a problematiche sociali, sofferenza animale o conseguenze negative dei sistemi produttivi tradizionali. Tuttavia, la loro incidenza inferiore rispetto alle emozioni positive indica che tali dimensioni non dominano il discorso complessivo.

Le emozioni di **anger** e **disgust** presentano frequenze relativamente basse. Questo dato suggerisce che il corpus, nel suo insieme, evita un linguaggio fortemente conflittuale o apertamente polemico, privilegiando piuttosto registri argomentativi, informativi o normativi.

Anche **surprise** risulta meno rappresentata, segnalando che il discorso tende a stabilizzarsi su narrazioni ormai consolidate, più che su elementi di rottura improvvisa o shock informativo.

Nel complesso, il profilo emotivo che emerge è dominato da fiducia, aspettativa e positività, con una presenza controllata di emozioni negative. Questo equilibrio conferma quanto emerso dalle analisi strutturali e tematiche: il corpus costruisce un discorso orientato alla legittimazione e alla normalizzazione del fenomeno, più che alla sua problematizzazione conflittuale. Tali risultati costituiscono una base interpretativa fondamentale per il successivo confronto del sentiment nei diversi periodi temporali, consentendo di valutare se e come questa configurazione emotiva evolva nel tempo.

Il grafico 65 mostra una chiara evoluzione del profilo emotivo del corpus nei tre periodi considerati (Early, Growth, Boom), evidenziando sia elementi di continuità sia cambiamenti significativi nell'intensità e nella gerarchia delle emozioni.




Figura 65: Analisi del sentiment secondo il modello di Plutchik lungo i tre periodi

L'analisi della distribuzione percentuale delle emozioni nei tre periodi (*Early*, *Growth*, *Boom*) consente di confrontare il profilo emotivo relativo del discorso, neutralizzando le differenze di ampiezza del corpus tra le fasi. I risultati di questo approccio mette in evidenza non tanto variazioni drastiche nel sentiment, quanto piuttosto una notevole stabilità strutturale del quadro emotivo complessivo.

In tutti e tre i periodi, *trust* emerge sistematicamente come l'emozione predominante, con valori percentuali compresi approssimativamente tra il 24% e il 26%. Tale ricorrenza indica che la dimensione di fiducia rappresenta una componente trasversale e persistente del discorso analizzato, più che una caratteristica specifica di una singola fase temporale.

Anche *anticipation* mantiene in modo costante una quota elevata (circa 17–20%), suggerendo che l'orientamento verso il futuro e le aspettative associate al fenomeno sono presenti fin dalle fasi iniziali e lungo tutti i periodi.

Le altre emozioni mostrano variazioni contenute e gradualità. *Joy* si colloca stabilmente intorno al 16–17% in tutti i periodi, mentre *fear* oscilla in un intervallo relativamente ristretto (circa 9–11%), senza evidenziare incrementi netti o discontinuità marcate.

Analogamente, *anger* e *sadness* mantengono percentuali moderate e comparabili tra le tre fasi, attestandosi intorno al 7–8%, mentre *disgust* rimane sistematica-

mente l'emozione meno rappresentata.

Nel complesso, il confronto percentuale suggerisce che non emergono differenze emotive nette o brusche tra i periodi *Early*, *Growth* e *Boom*. Piuttosto che una trasformazione del *sentiment*, si osserva una ricomposizione lieve e progressiva del peso relativo delle emozioni, che conserva un impianto emotivo sostanzialmente coerente nel tempo.

Questi risultati suggeriscono che l'evoluzione del corpus non è accompagnata da un cambiamento significativo del *sentiment* dominante, bensì da una stabilità emotiva di fondo, all'interno della quale le emozioni positive (*trust*, *anticipation*, *joy*) continuano a prevalere sulle componenti negative. Tale continuità rafforza l'interpretazione del discorso mediatico come progressivamente strutturato e normalizzato, più che come emotivamente polarizzato o conflittuale, e si pone in linea con quanto emerso dalle precedenti analisi tematiche e di *topic modeling*.

9.4 Confronto tra analisi dei commenti italiani e degli articoli internazionali

Il confronto tra i risultati ottenuti dall'analisi dei commenti YouTube e quelli relativi agli articoli giornalistici consente di evidenziare differenze sostanziali riconducibili non solo al contenuto trattato, ma soprattutto alla diversa natura comunicativa dei due corpora analizzati all'interno di questo lavoro. I commenti social e gli articoli informativi rappresentano infatti due contesti discorsivi profondamente differenti, che si riflettono in modo sistematico sia nelle strutture lessicali sia nelle dinamiche emotive emerse dalle analisi.

Dal punto di vista lessicale, i commenti YouTube si caratterizzano per una ricchezza relativamente contenuta e per un vocabolario fortemente ripetitivo, come confermato dal valore di TTR pari al 12,37%. Il linguaggio appare frammentato, colloquiale e spesso polarizzato, con una forte concentrazione di termini direttamente legati alla contrapposizione tra vegani e non vegani (ad esempio vegani, carne, animali). Le analisi di concordanza e di associazione mostrano come tali termini vengano frequentemente inseriti in argomentazioni di tipo etico, identitario o polemico, spesso semplificate e ricondotte a opposizioni nette tra posizioni contrapposte.

Al contrario, il corpus degli articoli presenta una struttura lessicale più stabile e

omogenea. L'analisi fattoriale delle corrispondenze e il *topic modeling* evidenziano una progressiva strutturazione del discorso, che evolve nel tempo da una fase iniziale incentrata su aspetti etici e salutistici a una fase più matura dominata da temi economici, industriali e ambientali. In questo contesto, il veganismo viene rappresentato prevalentemente come fenomeno sociale ed economico, inserito all'interno di logiche di mercato, innovazione e sostenibilità.

Differenze ancora più marcate emergono sul piano del *sentiment*. Nei commenti social, l'analisi basata su dizionari lessicali evidenzia una distribuzione relativamente equilibrata tra *sentiment* positivo, negativo e neutro, con una leggera prevalenza della componente negativa (36,5%). Questo risultato riflette il carattere conflittuale e polarizzato del dibattito online, in cui il confronto diretto tra utenti favorisce l'emergere di giudizi critici, attacchi identitari e prese di posizione emotivamente cariche.

Il *clustering* testuale conferma tale quadro, mostrando la coesistenza di registri polemici di natura scientifico-nutrizionale, identitaria ed etica.

Negli articoli, invece, l'analisi del *sentiment* condotta secondo il modello di Plutchik restituisce un profilo emotivo diverso. Le emozioni predominanti risultano essere trust e anticipation, seguite da joy, delineando un discorso complessivamente orientato alla legittimazione, alla credibilità e alla proiezione verso il futuro. La ridotta presenza di emozioni negative come anger o disgust è coerente con la natura informativa e argomentativa delle fonti analizzate, spesso favorevoli o comunque neutrali rispetto al tema del veganismo.

In sintesi, il confronto tra i due corpora mostra come il contesto comunicativo influenzi in modo decisivo sia la forma sia il contenuto del discorso. Nei commenti YouTube il veganismo emerge come oggetto di conflitto identitario e morale, fortemente polarizzato e carico emotivamente. Negli articoli informativi, al contrario, esso viene progressivamente normalizzato e istituzionalizzato, assumendo i tratti di un fenomeno strutturato, analizzato attraverso categorie economiche, scientifiche e sociali.

10 Conclusioni

Questo studio ha affrontato le tematiche delle abitudini alimentari e del veganesimo attraverso un metodo interdisciplinare, analizzando non solo i dati ufficiali, ma anche quelli provenienti dai social e da fonti giornalistiche.

L'analisi dei dati statistici ha evidenziato come le scelte alimentari non siano distribuite in modo omogeneo nella popolazione, ma presentino associazioni significative con variabili socio-demografiche, generazionali e culturali. Lo studio delle tecniche di riduzione della dimensionalità e *clustering* ha agevolato l'analisi dei fenomeni e lo studio della variabile BMI nel tempo ha consentito di osservare cambiamenti associati alle trasformazioni delle abitudini alimentari.

Nella seconda parte del lavoro, il focus si è spostato sull'analisi di commenti in lingua italiana estrapolati da un video YouTube, che rappresentano uno spazio privilegiato di espressione spontanea delle opinioni degli utenti. Attraverso tecniche di *text mining*, *clustering* e *sentiment analysis*, l'analisi ha messo in luce un dibattito fortemente polarizzato, articolato principalmente lungo tre dimensioni discorsive: la discussione scientifica e nutrizionale, la discussione sull'identità del vegano come persona, e la questione etica. In particolare, i risultati mostrano come la componente conflittuale non sia irrilevante, con un uso del linguaggio spesso orientato alla delegittimazione delle scelte alimentari alternative, più che a un confronto informativo.

Successivamente, l'analisi degli articoli giornalistici ha restituito un quadro parzialmente differente. I testi analizzati presentano infatti un registro più informativo e strutturato, in cui il veganismo e il mercato *plant-based* vengono frequentemente inquadrati in relazione a temi quali salute, sostenibilità ambientale, innovazione e crescita del settore. Pur non mancando riferimenti a controversie e criticità, il discorso giornalistico appare meno polarizzato rispetto a quello osservato nei commenti degli utenti, contribuendo a rappresentare il *plant-based* come un fenomeno economico e sociale in evoluzione.

Il confronto tra i commenti su YouTube e gli articoli dei giornali mostra differenze importanti. Queste differenze non si trovano solo nel modo di comunicare, ma anche nei contenuti e nei punti di vista. Tali divergenze possono essere interpretate anche alla luce della diversa dimensione territoriale e culturale dei corpora analizzati: i commenti vengono da un contesto italiano, che ha una tradizione alimentare molto specifica; gli articoli dei giornali, invece, presentano spesso una prospettiva internazionale, in cui il *plant-based* è inserito all'interno

di dinamiche di mercato globali. La distinzione che esiste tra le varie rappresentazioni del veganismo suggerisce che le immagini e le idee associate a questo stile di vita sono influenzate da due fattori principali: il mezzo attraverso cui vengono comunicate e il contesto culturale e alimentare in cui si sviluppano. Nel loro insieme, i risultati indicano che il mercato *plant-based* si sta progressivamente affermando come segmento rilevante del sistema alimentare, ma che tale evoluzione è accompagnata da resistenze culturali e simboliche, particolarmente evidenti nel dibattito online. In prospettiva, è plausibile attendersi una crescita ulteriore del mercato, trainata dall'ampliamento dell'offerta e dall'ingresso di nuovi target di consumatori.

In conclusione, l'obiettivo del presente lavoro è stato quello di comprendere le motivazioni alla base della scelta vegetariana e vegana, verificando se fosse possibile individuare pattern ricorrenti tra coloro che adottano tali regimi alimentari e analizzando, al contempo, il modo in cui queste scelte vengono percepite e accettate nel contesto italiano e internazionale.

L'integrazione tra analisi quantitativa dei dati statistici e analisi testuale dei commenti sui social media e degli articoli giornalistici ha consentito di mettere in luce come il vegetarianismo e il veganismo non rappresentino fenomeni omogenei, ma siano il risultato di motivazioni differenti (nutrizionali, etiche e identitarie) che si riflettono sia nei comportamenti sia nel discorso pubblico. In particolare, il confronto tra i diversi livelli di analisi ha evidenziato come, accanto a una crescente diffusione delle alternative *plant-based*, permangano nel contesto italiano resistenze culturali e atteggiamenti critici, che contribuiscono a rendere queste scelte alimentari oggetto di un dibattito ancora fortemente polarizzato.

Riferimenti bibliografici

- [1] Pravettoni, R. (n.d.). *Il cibo come elemento di identità culturale nel processo migratorio*.
- [2] Fondazione Dieta Mediterranea. (n.d.). *Lo scenario storico della dieta mediterranea*. Recuperato da <https://www.fondazionedietamediterranea.it/dieta-mediterranea/la-storia/lo-scenario-storico/>
- [3] Treccani. (n.d.). *I consumi alimentari in Italia: Uno specchio del cambiamento*. Recuperato da https://www.treccani.it/enciclopedia/i-consumi-alimentari-in-italia-uno-specchio-del-cambiamento_%28L%27Italia-e-le-sue-Regioni%29/
- [4] Università degli Studi di Roma Unitelma Sapienza. (n.d.). *Perché la dieta mediterranea è diventata un patrimonio UNESCO*. Recuperato da <https://www.unitelmasapienza.it/news/perche-la-dieta-mediterranea-e-diventata-un-patrimonio-unesco/>
- [5] Strozzi, M. (2015). *Come cambia l'educazione alimentare (1975-2015)*. In *Cultura del cibo*. Torino: UTET. Recuperato da [http://www.foodedu.it/upload/files/Come_cambia_l'educazione_Alimentare_\(1975-2015\)_-_saggio_di_Marisa_Strozzi_-_in_Cultura_Del_Cibo_-_UTET_2015.pdf](http://www.foodedu.it/upload/files/Come_cambia_l'educazione_Alimentare_(1975-2015)_-_saggio_di_Marisa_Strozzi_-_in_Cultura_Del_Cibo_-_UTET_2015.pdf)
- [6] Doppia Voce. (n.d.). *Acqua e territorio*. Recuperato da https://www.doppiavoce.com/?option=com_content&view=article&id=59%3Aacqua-a-territorio&catid=35%3Aacqua-a-territorio&Itemid=60&lang=
- [7] Food Affairs. (2025, September 16). *Cresce in Italia il consumo di prodotti vegetariani e vegani: Il profilo delle famiglie che scelgono il plant-based*. Recuperato da <https://www.foodaffairs.it/2025/09/16/cresce-in-italia-il-consumo-di-prodotti-vegetariani-e-vegani-ecco-il-profilo-delle-famiglie-che-scelgono-il-plant-based/>
- [8] Eurostat. (n.d.). *Overweight and obesity – BMI statistics*. Recuperato da https://ec.europa.eu/eurostat/statistics-explained/index.php?title=Overweight_and_obesity_-_BMI_statistics

- [9] Istituto Nazionale di Statistica. (n.d.). *Aspetti della vita quotidiana - Microdati*. Recuperato da <https://www.istat.it/microdati/aspetti-della-vita-quotidiana/>